

UNIVERSIDADE DE SÃO PAULO

Instituto de Ciências Matemáticas e de Computação

Desenvolvimento de Sistema de Visão Computacional para Automatização da Classificação Visual do Algodão

Rodrigo de Souza Oliveira

Dissertação de Mestrado do Programa de Mestrado Profissional em
Matemática, Estatística e Computação Aplicadas à Indústria (MECAI)

SERVIÇO DE PÓS-GRADUAÇÃO DO ICMC-USP

Data de Depósito:

Assinatura: _____

Rodrigo de Souza Oliveira

Desenvolvimento de Sistema de Visão Computacional para Automatização da Classificação Visual do Algodão

Dissertação apresentada ao Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, como parte dos requisitos para obtenção do título de Mestre em Ciências - Mestrado Profissional em Matemática, Estatística e Computação Aplicadas à Indústria.

Área de concentração: Matemática, Estatística e Computação

Orientadora: Profa. Dra. Gleici da Silva Castro Perdoná

Versão original

São Carlos

2024

É possível elaborar a ficha catalográfica em LaTeX ou incluir a fornecida pela Biblioteca. Para tanto observe a programação contida nos arquivos USPSC-modelo.tex e fichacatalografica.tex e/ou gere o arquivo fichacatalografica.pdf.

A biblioteca da sua Unidade lhe fornecerá um arquivo PDF com a ficha catalográfica definitiva, que deverá ser salvo como fichacatalografica.pdf no diretório do seu projeto.

Rodrigo de Souza Oliveira

**Development of a Computer Vision System for Automating the
Cotton Grade Classification**

Dissertation submitted to the Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, in partial fulfillment of the requirements for the degree of the Master in Science - Professional Masters in Mathematics, Statistics and Computing Applied to Industry.

Concentration area: Mathematics, Statistics and Computing

Advisor: Profa. Dra. Gleici da Silva Castro Perdoná

Original version

São Carlos

2024

ERRATA

A errata é um elemento opcional, que consiste de uma lista de erros da obra, precedidos pelas folhas e linhas onde eles ocorrem e seguidos pelas correções correspondentes. Deve ser inserida logo após a folha de rosto e conter a referência do trabalho para facilitar sua identificação, conforme a ABNT NBR 14724 (Associação Brasileira de Normas Técnicas, 2011).

Modelo de Errata:

OLIVEIRA, R. Desenvolvimento de Sistema de Visão Computacional para Automação da Classificação Visual do Algodão. 2024. 77 p. Dissertação (Mestrado em Ciências) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2024.

ERRATA

Folha	Linha	Onde se lê	Leia-se
1	10	auto-conclavo	autoconclavo

Folha de aprovação em conformidade
com o padrão definido
pela Unidade.

No presente modelo consta como
folhadeaprovacao.pdf

*Este trabalho é dedicado aos alunos da USP, como uma contribuição
das Bibliotecas do Campus USP de São Carlos para o desenvolvimento
e disseminação da pesquisa científica da Universidade.*

AGRADECIMENTOS

Primeira frase do agradecimento

Segunda frase

Outras frases

Última frase

*“O estudo, a busca da verdade e da beleza são domínios
em que nos é consentido sermos crianças por toda a vida.”*

Albert Einstein

RESUMO

OLIVEIRA, R. **Desenvolvimento de Sistema de Visão Computacional para Automação da Classificação Visual do Algodão**. 2024. 77 p. Dissertação (Mestrado em Ciências) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2024.

O resumo deve ressaltar o objetivo, o método, os resultados e as conclusões do documento. A ordem e a extensão destes itens dependem do tipo de resumo (informativo ou indicativo) e do tratamento que cada item recebe no documento original. O resumo deve ser precedido da referência do documento, com exceção do resumo inserido no próprio documento. (...) Salientamos que algumas Unidades exigem o título dos trabalhos acadêmicos em inglês, tornando necessário a inclusão das referências nos resumos e abstracts, o que foi adotado no **Modelo para TCC em $\text{\LaTeX}$ utilizando a classe USPSC** e no **Modelo para teses e dissertações em $\text{\LaTeX}$ utilizando a classe USPSC**. As palavras-chave devem figurar logo abaixo do resumo, antecidas da expressão Palavras-chave:, separadas entre si por ponto e finalizadas também por ponto (Associação Brasileira de Normas Técnicas, 2003).

Palavras-chave: LaTeX. Classe USPSC. Tese. Dissertação. Trabalho de conclusão de curso (TCC). Relatório.

ABSTRACT

OLIVEIRA, R. Development of a Computer Vision System for Automating the Cotton Grade Classification. 2024. 77 p. Dissertation (Master in Science) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2024.

This is the english abstract.

Keywords: LaTeX. USPSC class. Thesis. Dissertation. Conclusion course paper. Report.

LISTA DE FIGURAS

Figura 1	– Exemplo do Padrão Físico Universal (51.5: Cor Abaixo da Média, Branco / Grau de Folhas 5)	40
Figura 2	– Equipamento Uster HVI 1000	42
Figura 3	– Gráfico de cores e classificação manual e instrumental de fibras de algodão. No eixo vertical, estão os valores de reflectância. Quanto maior o valor, mais brilhante é o algodão. No eixo horizontal, estão valores típicos do índice de amarelo. Quanto maior o valor, mais amarela é a amostra.	44
Figura 4	– Acentuação (modo texto - $\text{\LaTeX}$)	75

LISTA DE TABELAS

Tabela 1 – Códigos dos tipos de Cor, Classes de Cor ou Grau de Cor do Algodão Upland	41
Tabela 2 – Resumo comparativos das principais características entre sensores CCD e CMOS	46
Tabela 3 – Exemplo de tabela centralizada verticalmente e horizontalmente	67
Tabela 4 – Exemplo de tabelas com grade	69

LISTA DE QUADROS

LISTA DE ABREVIATURAS E SIGLAS

USDA	Departamento de Agricultura dos Estados Unidos (<i>United States Department of Agriculture</i>)
MAPA	Ministério da Agricultura, Pecuária e Abastecimento
HVI	<i>High Volume Instrument</i>

LISTA DE SÍMBOLOS

Γ	Letra grega Gama
Λ	Lambda
ζ	Letra grega minúscula zeta
$\in$	Pertence

SUMÁRIO

1	INTRODUÇÃO	33
2	REVISÃO DA LITERATURA	37
2.1	Agronegócio Brasileiro e o Algodão	37
2.2	Qualidade do Algodão	38
2.2.1	Contexto histórico e econômico	38
2.2.2	Classificação do algodão no Brasil	39
2.2.2.1	Classificação visual	39
2.2.2.2	Classificação instrumental	42
2.2.3	Relação entre a classificação visual e instrumental	43
2.3	Visão Computacional	44
2.3.1	Sistemas de visão computacional	45
2.3.1.1	Captura de imagens	45
2.3.1.2	Iluminação	46
2.3.1.3	Software	47
2.3.2	Processamento e análise de imagens	47
2.3.3	Aplicações da visão computacional no Agronegócio	48
2.3.3.1	Classificação e Qualidade de Fibras	48
2.4	Inteligência Artificial	48
2.5	Lacunas na Literatura	49
3	METODOLOGIA	51
4	RESULTADOS ESPERADOS	53
5	DISCUSSÃO	55
6	CONCLUSÃO	57
	REFERÊNCIAS	59
	APÊNDICES	63
	APÊNDICE A – APENDICE(S)	65
	APÊNDICE B – EXEMPLO DE TABELA CENTRALIZADA VERTI- CALMENTE E HORIZONTALMENTE	67

APÊNDICE C – EXEMPLO DE TABELA COM GRADE	69
ANEXOS	71
ANEXO A – EXEMPLO DE ANEXO	73
ANEXO B – ACENTUAÇÃO (MODO TEXTO - $\text{\LaTeX}$)	75
ÍNDICE	77

1 INTRODUÇÃO

O Algodão (*Gossypium hirsutum* L.) é uma cultura com relevante importância no cenário internacional. Chegando a ser conhecido como "ouro branco" em diversos países, a fibra do algodão subsidia a indústria têxtil e tem um impacto econômico de cerca de 600 bilhões de dólares ao ano (Khan *et al.*, 2020). No Brasil, a produção de pluma de algodão gira em torno de 2,5 milhões de toneladas ao ano, em uma área plantada com cerca de 1,6 milhão de hectares (Conab, 2024).

Uma importante etapa dentro cadeia produtiva do algodão é a classificação da qualidade da fibra de acordo com níveis internacionais. Esses níveis de qualidade determinam o preço de comercialização e o poder de negociação do produto (Yaşar, 2021).

A classificação internacional da fibra começou com os americanos, em 1906, pelo Departamento de Agricultura dos Estados Unidos (USDA), que estabeleceu a padronização da qualidade da fibra, em um sistema que existe até hoje. Atualmente o USDA estabelece 15 padrões de classificação de algodão, que são atualizados todos os anos e servem como referência para as classificações visuais realizadas (Cotton Incorporated, 2017).

No Brasil, o processo de classificação é regulamentado pela Instrução Normativa n. 24/2016 do Ministério de Estado da Agricultura, Pecuária e Abastecimento (MAPA), que traça padrões para a classificação, com requisitos de identidade e qualidade, amostragem e apresentação do produto (MAPA, 2016).

No processo produtivo do algodão a classificação é feita por amostragem, e pode ser realizada de duas formas: por método visual ou por método instrumental. A classificação visual é realizada por classificador (pessoa física) tendo como base Padrões Físicos Universais, levando em conta a cor das fibras, a presença de folhas que irá caracterizar as impurezas, as contaminações de matérias estranhas e o modo de preparação (beneficiamento) do produto. Já a classificação instrumental é realizada por equipamento do tipo HVI (*High Volume Instrument*) (MAPA, 2016). A classificação instrumental demanda um tempo de análise considerável, bem como custos elevados, preparo das amostras e condições controladas em laboratório (Oliveira, 2022).

Após a produção do fardo do algodão beneficiado e a classificação é realizada a etapa de "emblocamento" que consiste na criação de blocos de algodão de aproximadamente 25 mil toneladas, compostos por fardos que possuem a mesma classificação (geralmente entre 110 e 125 fardos). Cada bloco é a menor unidade de comercialização.

Como o processo de beneficiamento nas algodoieiras ocorre 24 horas por dia e 7 dias por semana e devido a limitações logísticas, existe a necessidade de se realizar o "emblocamento" no menor tempo possível. Por isso, as empresas optam por realizar esta etapa do processo de acordo com a classificação visual, já que os resultados da classificação por instrumentos podem demorar

até 24 horas para chegar.

Mesmo com a classificação visual, que é mais rápida que a por instrumentos, existe um ponto de lentidão no processo, pois é necessário que as amostras sejam enviadas para as unidades de classificação e somente depois que o emblocamento é realizado. Ter as unidades de classificação dentro da indústria não se mostra viável pela necessidade de se ter um ambiente controlado para garantia da qualidade das amostras. Assim, ter equipamentos que possam ser instalados na indústria (após a geração dos fardos), que possam coletar, processar e analisar de forma automatizada as amostras de cada fardo, se mostra uma alternativa com grande potencial para melhoria do processo. Neste cenário, um sistema de visão computacional parece ser o mais adequado.

Visão computacional é a ciência responsável pela visão de uma máquina, pela forma como um computador enxerga o meio à sua volta, extraindo informações significativas a partir de imagens capturadas por diversos dispositivos como câmeras, sensores, scanners, etc. Estas informações permitem reconhecer, manipular e pensar sobre os objetos que compõem uma imagem (Ballard; Brown, 1982).

Por volta da década de 70, foram iniciados os primeiros estudos na área de visão computacional. Ao longo desses anos uma série de pesquisas foram conduzidas e técnicas de análise foram elaboradas, principalmente com o uso de inteligência artificial. Assim, a visão computacional fornece ao computador uma infinidade de informações precisas a partir de imagens e vídeos, de forma que o computador consiga executar tarefas inteligentes, simulando e aproximando-se da inteligência humana (Oliveira; Honorato, 2024).

Um sistema básico de visão computacional consiste em quatro características: iluminação, câmera, computador e software de processamento de imagens. Esse sistema vai permitir a captura da imagem, sua conversão digital para armazenamento e processamento no computador e o software de processamento de imagens será responsável pelo aprimoramento, segmentação, detecção ou classificação da imagem (Zhang; Li, 2014)

O sistema de iluminação deve ser capaz de destacar as características de interesse do objeto, em detrimento das demais características. É um sistema de extrema importância para se garantir a eficiência e a acurácia de um sistema de visão computacional, além de ter uma grande influência na qualidade das imagens. As chaves de um bom sistema de iluminação são aquelas que provêm uma iluminação uniforme com um espectro de características e que produzem imagens de alta qualidade (Thomasson; Shearer; Byler, 2005).

A câmera é o componente principal do sistema de visão computacional, que é usado para a aquisição da imagem e para a troca de dados com o computador. Existem diferentes tipos de dispositivos que capturam imagens em diversos espectros como monocromáticas, RGB, ultrassom, raios-x, NIR, etc (Brosnan; Sun, 2002).

A classificação visual por se tratar de um processo realizado manualmente e, apesar de

possuir um padrão, o resultado está sujeito à interpretação a à subjetividade do profissional que a está executando, muitas vezes abrindo margens para questionamentos e rejeições na fase de negociação da mercadoria.

Diante deste cenário, justifica-se a construção de um sistema que possibilite realizar a classificação visual do produto, seguindo todas as regulamentações necessárias e que elimine a subjetividade do processo e com velocidade. Assim, propõe-se este trabalho com o objetivo de construir um sistema automatizado de classificação do algodão, utilizando modelos de visão computacional e inteligência artificial, com o intuito de se ter uma maior padronização das classificações realizadas, bem como reduzir o número de rejeições da fase de negociação da mercadoria. Objetivos específicos: O hardware deve possibilitar a coleta e a classificação da amostra, sem depender de outros equipamentos ou softwares; A velocidade para a coleta da imagem, processamento e inferência deve ser adequada à demanda que a operação exige. Deve ser possível integrar via API os dados das amostras e suas classificações.

2 REVISÃO DA LITERATURA

Este capítulo tem como objetivo consolidar a linha de raciocínio fundamental para a elaboração dessa dissertação. Primeiramente será apresentado um panorama geral sobre o agronegócio brasileiro, com foco na cultura do algodão, abordando pontos como os principais desafios da produção, sua importância e seus destinos comerciais. Em seguida, detalha-se o processo de avaliação da qualidade do algodão, com ênfase nos padrões internacionais, regulamentações específicas no Brasil e os processos adotados na indústria. Na sequência, será contextualizado o tema dos sistemas de visão computacional, com aplicações no setor da agricultura, especialmente na classificação automatizada. Por fim, o capítulo discutirá o papel da inteligência artificial e os principais modelos empregados em sistemas de visão computacional.

2.1 Agronegócio Brasileiro e o Algodão

A agricultura brasileira já se consolidou como uma das maiores do mundo, fornecendo produtos essenciais para diversos setores da economia global, como a alimentação, a bioenergia, o setor têxtil entre outros. Essa consolidação é um reflexo de investimentos em inovações tecnológicas, que começaram com a terceira revolução agrícola (Revolução Verde) e se estendem até hoje com a disseminação da agricultura digital, integrando a agricultura de precisão e ferramentas como inteligência artificial para aumento da produtividade e sustentabilidade (Abbade, 2014; Basso; Neves; Sa, 2024).

O setor tem se destacado como um dos mais robustos, representando 23% da economia nacional (Filho *et al.*, 2024), com exportações atingindo recordes históricos. Mesmo em cenários de queda nos preços das commodities e desafios climáticos, como a seca e fenômenos como o El Niño (Lin; Qian, 2019) e desafios logísticos (Gonçalves *et al.*, 2024), o Brasil manteve o crescimento no valor total exportado. Em 2024, a expectativa é de que o país alcance US\$ 168,1 bilhões em exportações de produtos agrícolas, impulsionado por fatores como a desvalorização do real frente ao dólar, o que aumenta a competitividade dos produtos brasileiros no mercado internacional (Cardoso *et al.*, 2024).

No contexto da produção agrícola brasileira, a tecnologia desempenhou um papel essencial na adaptação do país a diferentes tipos de culturas, permitindo o cultivo de variedades mais resistentes e otimizadas para o clima tropical (Basso; Neves; Sa, 2024). Além disso, a introdução de biotecnologia e o avanço em estudos moleculares têm possibilitado o desenvolvimento de culturas com maior produtividade e resistência a pragas (Das *et al.*, 2023), sendo o algodão (*Gossypium hirsutum*) um exemplo significativo e cuja produção se beneficia de tais avanços, como resistência genética e técnicas de cultivo adaptadas ao clima e solo brasileiros (Ribeiro *et al.*, 2017; Ribeiro *et al.*, 2019; Ribeiro *et al.*, 2022).

Em 2024 o Brasil se consolidou como o maior exportador mundial de algodão em volume. As condições climáticas favoráveis, aliadas ao aumento da demanda internacional, permitiram um crescimento expressivo das exportações brasileiras de algodão em 2024. A produção alcançou 3,2 milhões de toneladas, com a China como principal destino, e as exportações estão projetadas para somar US\$ 5,2 bilhões até o fim do ano, um aumento de 56% em relação ao ano anterior. Isso reflete o papel estratégico do algodão na pauta exportadora do agronegócio brasileiro, que vai além da alimentação, abrangendo setores como o têxtil e de bioenergia (Cardoso *et al.*, 2024).

- Agro no Brasil (produção do agro, importância do algodão)
- Algodão (história, destinação)
- Algodão no Brasil e no cerrado (desafios)
- Números econômicos (Comercialização, principais importadores, etc.)

2.2 Qualidade do Algodão

A classificação e a avaliação da qualidade do algodão são processos fundamentais para a cadeia de produção e comércio dessa fibra, influenciando diretamente o valor de mercado e a adequação às diversas aplicações industriais. Nesta seção será examinado o histórico, os critérios de classificação e as normas internacionais, com destaque para o sistema estadunidense, além das especificidades regulatórias no Brasil.

2.2.1 Contexto histórico e econômico

A prática sistemática de classificação do algodão remonta do início do século XIX, tendo como origem na cidade de Liverpool na Inglaterra. A implementação dessa prática foi necessária devido à modernização das máquinas de fiar, impulsionada na primeira revolução industrial, onde se observou que a eficiência na produção de fios era maior dependendo da qualidade da fibra, gerando assim mais lucro para o fiador (Morais *et al.*, 2021). As transações comerciais da fibra do algodão passaram então a levar em conta sua qualidade, porém dependendo do setor envolvido (produtor ou fiador) a percepção sobre a qualidade da fibra mudava. Assim, foram desenvolvidos padrões para unificar e facilitar a comercialização da fibra. Nesse contexto, a criação de uma terminologia padronizada e de critérios objetivos de avaliação tornou-se essencial para a negociação e, especialmente, para garantir uma base de comparação justa que facilitasse as transações internacionais (Earle; Dean, 1914).

Conforme abordado por Conant (1915), a adoção do *United States Cotton Futures Act* pela Bolsa de Algodão de Nova York, que reformou as práticas de contratos futuros de algodão após pressões significativas, incluindo uma ameaça de imposto proibitivo. A principal mudança introduzida foi a substituição de um sistema arbitrário de fixação de diferenças de preço entre diferentes tipos de algodão por um sistema baseado nas diferenças comerciais reais do mercado à

vista. Esse novo sistema visava alinhar melhor os contratos futuros com a realidade do mercado, evitando distorções que prejudicavam tanto a proteção de *hedge* quanto a confiança no mercado. O ato também introduziu medidas de identificação por tipo para os fardos entregues em contrato e a supervisão direta do governo, trazendo mais transparência e equidade ao processo de negociação.

Earle e Dean (1914) também trazem que nos Estados Unidos, o sistema oficial de classificação foi desenvolvido no início do século XX, com a contribuição de produtores, especialistas e representantes do governo, resultando na formulação de nove padrões oficiais estabelecidos pelo Departamento de Agricultura (USDA). Na década de 1960 o USDA iniciou as pesquisas para desenvolver métodos instrumentais de classificação, que culminaram na adoção da classificação por HVI (*High Volume Instrument*) praticamente em toda a produção americana de algodão (Knowlton, 2005). Atualmente, apenas em casos especiais e identificação de corpos estranhos que o algodão é classificado de forma manual, porém pesquisas continuam sendo desenvolvidas para que a classificação instrumental contemple todos os aspectos avaliados (Incorporated, 2020).

2.2.2 Classificação do algodão no Brasil

No Brasil, o procedimento para a classificação da pluma do algodão é estabelecido pela Instrução Normativa n. 24 de 2016 do Ministério da Agricultura e leva em consideração Padrões Físicos Universais, como a cor da fibra, a presença de folhas e impurezas, contaminação de matérias estranhas e o modo de beneficiamento do produto (MAPA, 2016).


Tem início com o processo de amostragem, que leva em consideração os seguintes pontos:

- A amostra pode ser realizada manualmente ou mecanicamente;
- De cada fardo deve-se extrair duas amostras de lados opostos (no mínimo 150 gramas cada). Cada uma dessas amostras será dividida no sentido longitudinal e essa metade adicionada à metade da outra amostra, formando assim duas amostras de trabalho. Uma será enviada para classificação visual e outra para classificação instrumental;
- As amostras devem ser manuseadas e acondicionadas em pacotes de forma a não descaracterizá-las ao longo do processo;
- O tamanho das amostras deve ter no mínimo 25 a 30 centímetros de comprimento, 13 a 15 centímetros de largura e 8 a 13 centímetros de espessura;

2.2.2.1 Classificação visual

Após, uma das amostras retiradas seguem para o processo de classificação visual. Neste processo é utilizado como referência os Padrões Físicos Universais, que consistem em caixas com 6 amostras de algodão, tendo como base os padrões americanos para os algodões "*Upland*" e "*Pima*", conforme exemplo na Figura 1.

Figura 1 – Exemplo do Padrão Físico Universal (51.5: Cor Abaixo da Média, Branco / Grau de Folhas 5)



Fonte: Do Autor

A classificação do algodão é feita com base em tipos de cor e graus de folha, ambos representados por códigos que correspondem aos Padrões Físicos Universais. A Tabela 1 apresenta esses tipos de cor e suas respectivas classes. O grau de folha é uma escala que varia de 1 a 8, determinada pela quantidade de folhas presentes na amostra. Esses padrões devem ser visualizados e memorizados antes de iniciar a classificação, podendo ser consultados sempre que necessário.

Após a memorização dos padrões, as amostras devem ser divididas no sentido longitudinal ao meio, subdividindo as metades com cuidado para não descaracterizá-las durante o manuseio. As duas piores partes são selecionadas para análise, sendo a pior parte voltada para cima, para facilitar a análise.

Avalia-se a cor, brilho, manchas, impurezas, contaminações e defeitos de beneficiamento. A determinação do tipo é feita com base no Tipo de Cor e Grau de Folhas e o resultado é registrado no Laudo de Classificação.

Tabela 1 – Códigos dos tipos de Cor, Classes de Cor ou Grau de Cor do Algodão Upland

	Branco	Ligeiramente Creme	Creme	Avermelhado	Amarelado
Cor Boa Média - GM (Good Middling)	11	12	13	-	-
Cor Estritamente Média-SM (Strict Middling)	21	22	23	24	25
Cor Média-M (Middling)	31	32	33	34	35
Cor Estritamente Abaixo da Média-SLM (Strict Low Middling)	41	42	43	44	-
Cor Abaixo da Média-LM (Low Middling)	51	52	53	54	-
Cor Estritamente Boa Comum-SGO (Strict Good Ordinary)	61	62	63	-	-
Cor Boa Comum-GO (Good Ordinary)	71	-	-	-	-
Abaixo de Padrão	81	82	83	84	85

2.2.2.2 Classificação instrumental

Em paralelo a segunda amostra é enviada para a classificação instrumental, que é realizada em laboratório. O ambiente de trabalho deve atender a condições específicas de umidade e temperatura. As amostras devem estar em bandejas teladas ou perfuradas em uma única camada para garantir circulação de ar.

São utilizados equipamentos do tipo HVI (*High Volume Instrument*), que devem estar calibrados conforme as especificações do fabricante. Na Figura 2, é apresentado o modelo Uster HVI1000, que realiza a análise do HVI.

Figura 2 – Equipamento Uster HVI 1000



Fonte: (Uster Technologies, 2024)

O processo de análise consiste na análise de micronaire, que é feita em um corpo de prova, enquanto os outros parâmetros são analisados em dois corpos de prova por amostra. A amostra é submetida ao equipamento HVI para obtenção do relatório. O resultado é analisado e um documento de classificação é gerado.

Os parâmetros analisados são:

- Comprimento da Fibra (UHML): Comprimento médio da metade superior das fibras.
- Índice de Uniformidade do Comprimento da Fibra (%UI): Relação entre o comprimento médio total das fibras e o comprimento médio das fibras mais longas.
- Resistência ou Tenacidade da Fibra (Str): Medida da força necessária para romper as fibras, expressa em gf/tex.
- Alongamento à Ruptura da Fibra (%Elg): Percentual de extensão que a fibra suporta antes de romper.


- Micronaire da Fibra (Mic): Combinação de finura e maturidade da fibra.
- Grau de Reflectância (%Rd): Nível de luminosidade e cor branca refletida pelas fibras.
- Grau de Amarelamento (+b): Índice que expressa o nível de amarelamento da fibra.
- Índice de Fibras Curtas (%SFI): Percentual de fibras com comprimento inferior a 0,50 polegadas.
- Índice de Consistência da Fiação (SCI): Valor calculado com base nas propriedades físicas das fibras e sua correlação com a performance de fiação.

2.2.3 Relação entre a classificação visual e instrumental

Nickerson e Newton (1958) chegaram à relação entre a reflectância (%Rd) e o índice de amarelo (+b) com a classificação do algodão por meio de um estudo detalhado que utilizou o Colorímetro Nickerson-Hunter. Este instrumento mede a cor do algodão em termos destes dois atributos, permitindo uma representação em um gráfico bidimensional. Para converter essas medidas em uma classificação de cor única, os autores desenvolveram um índice que relaciona os valores medidos com os padrões oficiais de tipo de algodão.

A análise envolveu encontrar uma linha de melhor ajuste entre os dados medidos e os padrões de cor, utilizando métodos de regressão para obter fórmulas de conversão e diagramas que facilitassem essa associação (Figura 3). Essa abordagem permitiu criar índices numéricos para diferentes estados do algodão, como fibras em estado bruto e fios tingidos, mantendo o valor de *Middling* (Cor Média) em 100 e ajustando as relações para outros graus de cor.

Figura 3 – Gráfico de cores e classificação manual e instrumental de fibras de algodão. No eixo vertical, estão os valores de reflectância. Quanto maior o valor, mais brilhante é o algodão. No eixo horizontal, estão valores típicos do índice de amarelo. Quanto maior o valor, mais amarela é a amostra.



Fonte: Cotton Incorporated (2024)

2.3 Visão Computacional

Neste capítulo será explorada com mais profundidade a disciplina de visão computacional, os sistemas de visão computacional e seus conceitos fundamentais, o processamento de imagens e aplicação da visão computacional no agro, com ênfase nas tecnologias e métodos aplicados à cultura do algodão.

Oliveira e Honorato (2024) descrevem o histórico da visão computacional como uma ciência recente, cuja primeira menção foi em 1955, com a ideia de equipar computadores com "olhos e ouvidos". Na década de 1970, os primeiros estudos combinaram visão computacional

com inteligência artificial, acreditando que a emulação da visão humana por máquinas seria rapidamente alcançada. Destaque para Marr (1976) que, dentro do campo da neurofisiologia, desenvolveu uma abordagem computacional para a visão, que consistia na formulação de um algoritmo para interpretação visual em qualquer contexto físico. Seus estudos foram um dos principais pontos de partida para as pesquisas em visão computacional (Vaina, 2004).

No entanto, descobriu-se que a complexidade era maior do que imaginado, devido à falta de informações sobre a interpretação de imagens pelo cérebro humano, levando a avanços progressivos nas décadas seguintes (Oliveira; Honorato, 2024), resultando na consolidação da visão computacional como a disciplina que busca desenvolver métodos e algoritmos para que os computadores possam interpretar e entender imagens de forma semelhante à percepção humana (Ballard; Brown, 1982).

2.3.1 Sistemas de visão computacional

Saldaña *et al.* (2013) discute que os sistemas de visão computacional são projetados para extrair e analisar informações de objetos de forma automática e objetiva, sendo rápidos, consistentes e não invasivos. Esses sistemas geralmente consistem em um dispositivo de captura de imagens, dispositivo de iluminação e um computador que processa as imagens capturadas.

2.3.1.1 Captura de imagens

Existem diferentes sensores que podem ser utilizados para gerar uma imagem, como ultrassom, raios-X, sensores térmicos, sensores de espectroscopia de infravermelho próximo (NIR) e câmeras tradicionais, estas geralmente mais utilizadas em problemas de visão computacional (Brosnan; Sun, 2004).

As câmeras são responsáveis pela captura da imagem, que é então convertida em sinais eletrônicos e processada. Basicamente, existem dois tipos de sensores: as câmeras CCD (*Charge-Coupled Device*) e CMOS (*Complementary Metal-Oxide-Semiconductor*).

As câmeras CCD são reconhecidas pela alta qualidade de imagem que oferecem, especialmente em condições de baixa iluminação. Isso ocorre devido ao menor ruído intrínseco de seus sensores, que apresentam substratos mais silenciosos e menor quantidade de circuitos integrados no chip. Além disso, os sensores CCD possuem maior faixa dinâmica, proporcionando uma melhor relação entre os níveis de saturação e o limite inferior de sinal detectável, o que resulta em imagens mais detalhadas e com melhor gradação tonal. Outra vantagem significativa das câmeras CCD é a uniformidade na resposta dos pixels, o que as torna ideais para aplicações que exigem alta precisão, como fotografia científica, televisores de alta performance e aplicações médicas. No entanto, essa tecnologia apresenta desvantagens como maior consumo de energia e tamanho físico do sistema, já que muitas funções do sensor dependem de circuitos externos (Littwiller, 2001).

Os sensores CMOS evoluíram significativamente nas últimas décadas, consolidando-se como uma alternativa viável aos CCDs, especialmente em aplicações que demandam baixo custo, baixo consumo de energia e integração de múltiplas funcionalidades em um único chip. A arquitetura CMOS permite a integração de circuitos analógicos e digitais diretamente no sensor, resultando em sistemas menores e mais leves. Além disso, sensores CMOS consomem menos energia, podendo operar com uma única fonte de baixa tensão, o que os torna ideais para dispositivos móveis e portáteis. Apesar dessas vantagens, os CMOS ainda enfrentam desafios como menor sensibilidade, maior ruído em condições de baixa iluminação e menor faixa dinâmica (Bigas *et al.*, 2006). Na Tabela 2 é apresentado um resumo comparando as principais características dos sensores CCD e CMOS, apresentados por Bigas *et al.* (2006).

Tabela 2 – Resumo comparativos das principais características entre sensores CCD e CMOS

Característica	CCD	CMOS
Consumo de energia	Alto	Baixo
Custo	Alto	Baixo
Integração em chip	Não	Sim
Flexibilidade	Limitada	Alta
Faixa dinâmica	Alta	Limitada
Sensibilidade	Alta	Limitada
Ruído	Baixo	Alto
Qualidade de imagem	Alta	Limitada
Velocidade	Limitada	Alta
Tamanho físico do sistema	Maior	Menor
Aplicações	Alta qualidade, ciências	Dispositivos móveis, segurança

Fonte: Bigas *et al.* (2006)

FALAR AQUI SOBRE FORMA DE TRANSMITIR IMAGENS E COMPACTAÇÃO JPG E BMP

2.3.1.2 Iluminação

A iluminação desempenha um papel essencial nos sistemas de visão computacional, pois define as propriedades ópticas dos objetos a serem analisados. A luz incidente pode ser absorvida, refletida ou transmitida, influenciando diretamente a qualidade das imagens capturadas. Para otimizar o desempenho do sistema de visão, a escolha e a configuração do sistema de iluminação devem ser adaptadas à aplicação específica. Essa seleção cuidadosa reduz a necessidade de etapas complexas de processamento de imagem, aumentando a eficiência e a precisão das análises (Chen; Chao; Kim, 2002).

Zhang e Li (2014) destacam a importância de fontes de luz que realcem as características dos objetos e permitam distinções claras entre as partes detectadas e outras áreas. A eficiência e a precisão de um sistema de visão computacional dependem significativamente da qualidade

da iluminação, que deve fornecer luz uniforme e estável, além de evitar reflexos e sombras que possam comprometer a análise.

A escolha da iluminação ideal depende das características espectrais desejadas para a aplicação, considerando tanto a geometria do objeto quanto os atributos a serem destacados. Por exemplo, sistemas que utilizam luz difusa são eficazes para minimizar reflexos especulares, enquanto a iluminação traseira pode ser essencial para delinear contornos e aumentar o contraste em objetos translúcidos. Diferentes tipos de lâmpadas são utilizados, incluindo tubos de raios X, fluorescentes, incandescentes, lasers e lâmpadas de infravermelho, cada uma operando em faixas espectrais específicas, desde raios X (0,01-10 nm) até o infravermelho próximo (700-2500 nm). Enquanto as lâmpadas fluorescentes são preferidas para análises baseadas em luz visível, os LEDs têm ganhado destaque por sua estabilidade, baixo consumo de energia e ampla disponibilidade em comprimentos de onda específicos (Cubero *et al.*, 2010).

2.3.1.3 Software

????

2.3.2 Processamento e análise de imagens

O processamento e a análise das imagens são componentes fundamentais nos sistemas de visão computacional, desempenhando um papel crucial na extração de informações visuais úteis para a classificação, detecção de defeitos e avaliação de qualidade (Krutz *et al.*, 2000).

Segundo Brosnan e Sun (2002), o processamento de imagens engloba operações destinadas a melhorar a qualidade das imagens capturadas, removendo ruídos, corrigindo distorções geométricas e uniformizando a iluminação. Essas etapas iniciais são essenciais para garantir que as imagens estejam adequadamente preparadas para a análise subsequente. Já a análise de imagens refere-se à segmentação e à extração de características dos objetos de interesse, como forma, cor e textura, permitindo a interpretação e o reconhecimento dos elementos nas imagens.

O processamento/análise de imagens é frequentemente dividido em três níveis: o processamento de baixo nível, que inclui a aquisição e o pré-processamento de imagens; o processamento de nível intermediário, focado na segmentação, representação e descrição; e o processamento de alto nível, que envolve o reconhecimento e a interpretação de padrões (Gunasekaran, 1996; Sun, 2000).

A aquisição consiste na conversão do sinal eletrônico do sensor para uma forma numérica. O pré-processamento refere-se ao processamento inicial dos dados brutos da imagem para correção de distorções geométricas, remoção de ruídos, correção do nível de cinza e correção de desfoque (Shirai, 1987). O objetivo dessa etapa é melhorar a qualidade da imagem, removendo distorções indesejadas ou destacando características de interesse.

No nível intermediário, a segmentação de imagens é uma das etapas mais importantes em

toda a técnica de processamento de imagens, pois os dados extraídos posteriormente dependem fortemente da precisão dessa operação. Seu principal objetivo é dividir uma imagem em regiões que possuam uma forte correlação com objetos ou áreas de interesse. A segmentação pode ser realizada por três técnicas diferentes: limiarização, segmentação baseada em bordas e segmentação baseada em regiões. A representação se refere à maneira como a forma ou estrutura de um objeto é modelada e armazenada, seja por contornos, áreas, momentos ou outras técnicas que traduzem os dados visuais para formatos matemáticos ou computacionais. Descrição, por sua vez, é o processo de derivar atributos ou características mensuráveis a partir dessa representação, como tamanho, forma, textura ou relações espaciais, que podem ser usadas para classificação, reconhecimento ou análise mais profunda (Sonka; Hlavac; Boyle, 1993).

O processamento de alto nível envolve o reconhecimento e interpretação de padrões, que visam a transformação de dados visuais em informações compreensíveis. Sonka, Hlavac e Boyle (1993) trazem também que o reconhecimento de padrões refere-se à identificação de objetos ou estruturas em uma imagem com base em suas características distintivas, utilizando métodos como aprendizado estatístico, redes neurais, e técnicas sintáticas para classificar ou agrupar dados visuais. Já a interpretação de padrões vai além, envolvendo o uso de conhecimento contextual e estratégias hierárquicas para compreender o significado dos objetos reconhecidos e suas relações no ambiente analisado.

2.3.3 Aplicações da visão computacional no Agronegócio

A visão computacional tem desempenhado um papel fundamental no agronegócio, sendo aplicada em áreas como classificação de culturas, detecção de doenças, monitoramento de qualidade, automação de processos e muito mais. A seguir, apresentam-se os principais estudos categorizados por aplicação.

2.3.3.1 Classificação e Qualidade de Fibras

(Li *et al.*, 2023) propuseram algoritmos para medir a cor do algodão em pluma, corrigindo distorções e melhorando a classificação de qualidade.

2.4 Inteligência Artificial

- Contextualizar o que é IA
- Modelos de imagem
- PCANet
- VGGNet
- CNN
- SVM

- ???

2.5 Lacunas na Literatura

3 METODOLOGIA

4 RESULTADOS ESPERADOS

5 DISCUSSÃO

6 CONCLUSÃO

Apresentar as conclusões correspondentes aos objetivos ou hipóteses propostos para o desenvolvimento do trabalho, podendo incluir sugestões para novas pesquisas.

REFERÊNCIAS

- ABBADE, E. B. O papel do agronegócio brasileiro no seu desenvolvimento econômico. **Revista Gestão da Produção Operações e Sistemas**, v. 9, n. 3, p. 149, ago. 2014. Disponível em: <https://revista.feb.unesp.br/gepros/article/view/1053>.
- ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR 6028**: informação e documentação: resumo: apresentação. Rio de Janeiro, 2003. 2 p.
- ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR 14724**: informação e documentação: trabalhos acadêmicos: apresentação. Rio de Janeiro, 2011. 11 p.
- BALLARD, D. H.; BROWN, C. M. **Computer Vision**. Englewood Cliffs, NJ, USA: Prentice Hall, 1982. ISBN 9780131653160.
- BASSO, M. F.; NEVES, M. F.; SA, M. F. Grossi-de. Agriculture evolution, sustainability and trends, focusing on brazilian agribusiness: A review. **Frontiers in Sustainable Food Systems**, Frontiers, v. 7, p. 1–18, 2024. Disponível em: <https://www.frontiersin.org/articles/10.3389/fsufs.2023.1296337/full>.
- BIGAS, M. *et al.* Review of cmos image sensors. **Microelectronics Journal**, Elsevier, v. 37, n. 5, p. 433–451, 2006.
- BROSNAN, T.; SUN, D.-W. Inspection and grading of agricultural and food products by computer vision systems - a review. **Computers and Electronics in Agriculture**, v. 61, p. 193–213, 11 2002.
- BROSNAN, T.; SUN, D.-W. Improving quality inspection of food products by computer vision—a review. **Journal of Food Engineering**, Elsevier, v. 61, n. 1, p. 3–16, 2004.
- CARDOSO, V. M. *et al.* Perspectivas para as exportações do agronegócio brasileiro em 2024. **Comércio Internacional | Insper Agro Global**, Insper Agro Global, Setembro 2024. Working paper n.5/2024. Disponível em: <https://agro.insper.edu.br/>.
- CHEN, Y.-R.; CHAO, K.; KIM, M. S. Machine vision technology for agricultural applications. **Computers and Electronics in Agriculture**, Elsevier, v. 36, n. 2-3, p. 173–191, 2002.
- CONAB, C. N. d. A. **Série Histórica das Safras**. 2024. Disponível em: <https://www.conab.gov.br/info-agro/safras/serie-historica-das-safras>. Acesso em: 26 out. 2024.
- CONANT, L. J. The united states cotton futures act. **The American Economic Review**, American Economic Association, v. 5, n. 1, p. 1–11, 1915. Disponível em: <https://www.jstor.org/stable/71>.
- Cotton Incorporated. **Classification of Cotton**. 2017. Acessado em: 27 out. 2024. Disponível em: <https://www.cottoninc.com/wp-content/uploads/2017/02/Classification-of-Cotton.pdf>.
- Cotton Incorporated. **HVI Color Chart - U.S. Cotton Fiber Chart**. 2024. Acesso em: 9 nov. 2024. Disponível em: <https://www.cottoninc.com/cotton-production/quality/us-cotton-fiber-chart/hvi-color-chart/>.

CUBERO, S. *et al.* Advances in machine vision applications for automatic inspection and quality evaluation of fruits and vegetables. **Food and Bioprocess Technology**, Springer, v. 4, n. 4, p. 487–504, 2010.

DAS, S. *et al.* Role of biotechnology in creating sustainable agriculture. **PLOS Sustainability and Transformation**, Public Library of Science, v. 2, n. 7, p. 1–13, 07 2023. Disponível em: <https://doi.org/10.1371/journal.pstr.0000069>.

EARLE, D. E.; DEAN, W. S. **The Classification and Grading of Cotton**. Washington, DC: US Department of Agriculture, Farmers' Bulletin No. 591, 1914. Contribuição do Bureau de Tecnologia Agrícola e Padronização do Algodão.

FILHO, U. A. S. *et al.* Produto interno bruto e pegada hídrica do agronegócio: comparativo entre países. **Revista de Economia e Sociologia Rural**, Sociedade Brasileira de Economia e Sociologia Rural, v. 62, n. 4, p. e274229, 2024. ISSN 0103-2003. Disponível em: <https://doi.org/10.1590/1806-9479.2023.274229pt>.

GONÇALVES, E. M. d. O. *et al.* Os principais desafios da logística de transporte do agronegócio brasileiro: uma revisão sistemática da literatura. v. 15, p. e4073, ago. 2024. Disponível em: <https://ojs.revistagesec.org.br/secretariado/article/view/4073>.

GUNASEKARAN, S. Computer vision technology for food quality assurance. **Trends in Food Science & Technology**, Elsevier, v. 7, p. 245–256, 1996.

INCORPORATED, C. **The Classification of Cotton**. Cary, NC: Cotton Incorporated, 2020. Produzido com o suporte do Cotton Council International e o USDA Agricultural Marketing Service.

KHAN, M. A. *et al.* World cotton production and consumption: An overview. *In: ____*. **Cotton Production and Uses: Agronomy, Crop Protection, and Postharvest Technologies**. Singapore: Springer Singapore, 2020. p. 1–7. ISBN 978-981-15-1472-2. Disponível em: https://doi.org/10.1007/978-981-15-1472-2_1.

KNOWLTON, J. L. Usda cotton classing and the need for a universal cotton quality evaluation system. *In: EFS® Systems Conference, Turkey*, <http://www.cottoninc.com/EFSCConference>. [S.l.: s.n.], 2005.

KRUTZ, G. W. *et al.* Colour vision in forest and wood engineering. 2000.

LI, H. *et al.* A novel method for seed cotton color measurement based on machine vision technology. **Computers and Electronics in Agriculture**, v. 215, p. 108381, 2023.

LIN, J.; QIAN, T. Switch between el nino and la nina is caused by subsurface ocean waves likely driven by lunar tidal forcing. **Scientific Reports**, v. 9, n. 1, 2019. Disponível em: <https://doi.org/10.1038/s41598-019-49678-w>.

LITTWILLER, D. M. **CCD vs CMOS: Facts and Fiction**. 2001. Disponível em: <https://courses.cs.duke.edu/fall11/cps274/papers/Littwiller01.pdf>. Acesso em: 17 nov. 2024.

MAPA, M. d. A. P. e. A. **Instrução Normativa N° 24, de 14 de Julho de 2016**. 2016. Disponível em: https://www.in.gov.br/materia/-/asset_publisher/Kujrw0TZC2Mb/content/id/21289371/do1-2016-07-15-instrucao-normativa-n-24-de-14-de-julho-de-2016-21289194. Acesso em: 26 out. 2024.

MARR, D. From computational theory to psychology and neurophysiology: A case study from vision. **MIT Artificial Intelligence Laboratory Working Paper**, Cambridge, MA, n. 131, 1976. Discussão sobre níveis de descrição em processamento de informação visual e exemplos práticos.

MORAIS, J. P. S. *et al.* **Interpretação das características avaliadas no SITC para qualidade de fibra de algodão - Uma abordagem prática**. Campina Grande, PB: Embrapa Algodão, 2021. (Documentos / Embrapa Algodão, 285). ISSN 0103-0205.

NICKERSON, D.; NEWTON, F. E. **Grade and Color Indexes Developed for Evaluating Results of USDA Cotton Finishing Tests**. Washington, D.C.: United States Department of Agriculture, Agricultural Marketing Service, Cotton Division, 1958. Documento histórico arquivado.

OLIVEIRA, D. d. M.; HONORATO, L. B. Visão computacional. **Universidade Estadual de Campinas, Faculdade de Tecnologia**, Limeira, SP, Brasil, 2024. Artigo introdutório sobre visão computacional com foco em rastreamento de olhar.

OLIVEIRA, D. G. D. B. **Classificação e Determinação dos Atributos de Qualidade das Fibras de Algodão Utilizando um Espectrômetro Raman Portátil e Quimiometria**. 2022. 104 f. Dissertação (Mestrado em Química) — Universidade Estadual da Paraíba, Campina Grande, PB, Brasil, 2022.

RIBEIRO, T. P. *et al.* Transgenic cotton expressing cry10aa toxin confers high resistance to the cotton boll weevil. **Plant Biotechnology Journal**, v. 15, n. 8, p. 997–1009, 2017. Disponível em: <https://onlinelibrary.wiley.com/doi/abs/10.1111/pbi.12694>.

RIBEIRO, T. P. *et al.* Stability and tissue-specific cry10aa overexpression improves cotton resistance to the cotton boll weevil. **Biotechnology Research and Innovation**, v. 3, p. 27–41, 2019. ISSN 2452-0721. Strategies for crop improvement under biotic and abiotic stresses. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2452072119301352>.

RIBEIRO, T. P. *et al.* Stabilized double-stranded rna strategy improves cotton resistance to cbw (anthonomus grandis). **International Journal of Molecular Sciences**, v. 23, n. 22, 2022. ISSN 1422-0067. Disponível em: <https://www.mdpi.com/1422-0067/23/22/13713>.

SALDAÑA, E. *et al.* Review: Computer vision applied to the inspection and quality control of fruits and vegetables. **Brazilian Journal of Food Technology**, Instituto de Tecnologia de Alimentos, v. 16, n. 4, p. 254–272, 2013.

SHIRAI, Y. **Three-Dimensional Computer Vision**. Berlin, Heidelberg: Springer-Verlag, 1987. 28–30 p. ISBN 978-3-642-82431-9.

SONKA, M.; HLAVAC, V.; BOYLE, R. **Image Processing, Analysis, and Machine Vision**. London, UK: Chapman & Hall, 1993. 112–191 p. ISBN 978-0-412-45570-4.

SUN, D.-W. Inspecting pizza topping percentage and distribution by a computer vision method. **Journal of Food Engineering**, Elsevier, v. 44, n. 4, p. 245–249, 2000.

THOMASSON, J.; SHEARER, S.; BYLER, R. Image-processing solution to cotton color measurement problems: Part i. instrument design and construction. **Transactions of the American Society of Agricultural Engineers**, v. 48, 03 2005.

UNIVERSIDADE DE SÃO PAULO. Agência USP de Gestão da Informação Acadêmica. **Diretrizes para apresentação de dissertações e teses da USP: parte I (ABNT)**. 4. ed. São Paulo: AGUIA, 2020. 75 p. (Cadernos de Estudos, 9). Disponível em: <http://www.livrosabertos.sibi.usp.br/portaldelivrosUSP/catalog/view/459/413/2006-1.pdf>. Acesso em: 13 ago. 2021.

Uster Technologies. **Uster HVI - Cotton Classing**. 2024. Acesso em: 9 nov. 2024. Disponível em: <https://www.uster.com/products/cotton-classing/uster-hvi/>.

VAINA, L. M. Contributions of david marr to vision and neuroscience. **Encyclopedia of Cognitive Science**, Wiley, 2004. Explora as contribuições de Marr para a visão computacional e a neurociência teórica.

YAŞAR, S. Quality parameters of cotton fibre. *In*: _____. **Cotton Production Under Abiotic Stress**. Diyarbakir, Turkey: Springer, 2021. cap. 8, p. 215–234. Disponível em: <https://doi.org/10.1007/978-3-030-77278-1>.

ZHANG, H.; LI, D. Applications of computer vision techniques to cotton foreign matter inspection: A review. **Computers and Electronics in Agriculture**, Elsevier, v. 109, p. 59–70, 2014.

APÊNDICES

APÊNDICE A – APENDICE(S)

Os apêndices devem ser identificados por letras maiúsculas consecutivas, seguidas de hífen e pelos respectivos títulos. Excepcionalmente, utilizam-se letras maiúsculas dobradas na identificação dos apêndices, quando esgotadas as 26 letras do alfabeto. A paginação deve ser contínua, dando seguimento ao texto principal. (Universidade de São Paulo, 2020)

APÊNDICE B – EXEMPLO DE TABELA CENTRALIZADA VERTICALMENTE E HORIZONTALMENTE

A Tabela 3 exemplifica como proceder para obter uma tabela centralizada verticalmente e horizontalmente.

Tabela 3 – Exemplo de tabela centralizada verticalmente e horizontalmente

Coluna A	Coluna B
Coluna A, Linha 1	Este é um texto bem maior para exemplificar como é centralizado verticalmente e horizontalmente na tabela. Segundo parágrafo para verificar como fica na tabela
Quando o texto da coluna A, linha 2 é bem maior do que o das demais colunas	Coluna B, linha 2

Fonte: Elaborada pelos autores.

APÊNDICE C – EXEMPLO DE TABELA COM GRADE

A Tabela 4 exemplifica a inclusão de traços estruturadores de conteúdo para melhor compreensão do conteúdo da tabela, em conformidade com as normas de apresentação tabular do IBGE.

Tabela 4 – Exemplo de tabelas com grade

Coluna A	Coluna B
A1	B1
A2	B2
A3	B3
A4	B4

Fonte: Elaborada pelos autores.

ANEXOS

ANEXO A – EXEMPLO DE ANEXO

Elemento opcional, que consiste em um texto ou documento não elaborado pelo autor, que serve de fundamentação, comprovação e ilustração, conforme a ABNT NBR 14724. (Associação Brasileira de Normas Técnicas, 2011).

O **ANEXO B** exemplifica como incluir um anexo em pdf.

ANEXO B – ACENTUAÇÃO (MODO TEXTO - $\text{\LaTeX}$)Figura 4 – Acentuação (modo texto - $\text{\LaTeX}$)

$\text{\textbackslash'a}$ - á
 $\text{\textbackslash'a}$ - à
 $\text{\textbackslash~a}$ - ã
 $\text{\textbackslash^a}$ - â
 $\text{\textbackslash'e}$ - é
 $\text{\textbackslash^e}$ - ê
 $\text{\textbackslash'\{i\}}$ - í
 $\text{\textbackslash'I}$ - Í
 $\text{\textbackslash'o}$ - ó
 $\text{\textbackslash~o}$ - õ
 $\text{\textbackslash^o}$ - ô
 $\text{\textbackslash'u}$ - ú
 $\text{\textbackslash"u}$ - ü
 $\text{\textbackslashc{c}}$ - ç
 $\text{\textbackslashc{C}}$ - Ç

ÍNDICE

tabelas, 65, 67