

UNIVERSIDADE DE SÃO PAULO

Instituto de Ciências Matemáticas e de Computação

Da Convolução à Atenção: Uma Análise Comparativa de Paradigmas de Deep Learning para a Classificação de Algodão

Rodrigo de Souza Oliveira

Dissertação de Mestrado do Programa de Mestrado Profissional em Matemática, Estatística e Computação Aplicadas à Indústria (MECAI)

SERVIÇO DE PÓS-GRADUAÇÃO DO ICMC-USP

Data de Depósito:

Assinatura: _____

Rodrigo de Souza Oliveira

Da Convolução à Atenção: Uma Análise Comparativa de Paradigmas de Deep Learning para a Classificação de Algodão

Dissertação apresentada ao Instituto de Ciências Matemáticas e de Computação – ICMC-USP, como parte dos requisitos para obtenção do título de Mestre – Mestrado Profissional em Matemática, Estatística e Computação Aplicadas à Indústria.
EXEMPLAR DE DEFESA

Área de Concentração: Matemática, Estatística e Computação

Orientadora: Profa. Dra. Gleici da Silva Castro Perdoná

USP – São Carlos
Setembro de 2025

Ficha Exemplo

Utilize o link: <https://www.icmc.usp.br/institucional/estrutura-administrativa/biblioteca/servicos/ficha> para montar a ficha da sua dissertação e substitua essa.

Ficha catalográfica elaborada pela Biblioteca Prof. Achille Bassi
e Seção Técnica de Informática, ICMC/USP,
com os dados inseridos pelo(a) autor(a)

A634m Antonelli, Humberto Lidio
 Modelo de teses e dissertações em LaTeX do ICMC /
Humberto Lidio Antonelli; orientador Renata Pontin
de Mattos Fortes. -- São Carlos, 2018.
 81 p.

 Tese (Doutorado - Programa de Pós-Graduação em
Ciências de Computação e Matemática Computacional) --
Instituto de Ciências Matemáticas e de Computação,
Universidade de São Paulo, 2018.

 1. Modelo. 2. Monografia de qualificação. 3.
Dissertação. 4. Tese. 5. Latex. I. Fortes, Renata
Pontin de Mattos, orient. II. Título.

Bibliotecários responsáveis pela estrutura de catalogação da publicação de acordo com a AACR2:
Gláucia Maria Saia Cristianini - CRB - 8/4938
Juliana de Souza Moraes - CRB - 8/6176

Rodrigo de Souza Oliveira

**Da Convolução à Atenção: Uma Análise Comparativa de
Paradigmas de Deep Learning para a Classificação de
Algodão**

Dissertation submitted to the Instituto de Ciências Matemáticas e de Computação – ICMC-USP – in accordance with the requirements of the Professional Master's Program in Mathematics Statistics and Computing Applied to Industry, for the degree of Master in Science. *EXAMINATION BOARD PRESENTATION COPY*

Concentration Area: Mathematics, Statistics and Computing

Advisor: Profa. Dra. Gleici da Silva Castro Perdoná

**USP – São Carlos
September 2025**

Este trabalho é dedicado às ...

AGRADECIMENTOS

Os agradecimentos vão para...

“texto aqui”
(ddd)

RESUMO

OLIVEIRA, R. **Da Convolução à Atenção: Uma Análise Comparativa de Paradigmas de Deep Learning para a Classificação de Algodão**. 2025. 80 p. Dissertação (Mestrado – Mestrado Profissional em Matemática, Estatística e Computação Aplicadas à Indústria) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2025.

RESUMO

Palavras-chave: tag, tag, tag.

ABSTRACT

OLIVEIRA, R. **Da Convolução à Atenção: Uma Análise Comparativa de Paradigmas de Deep Learning para a Classificação de Algodão.** 2025. 80 p. Dissertação (Mestrado – Mestrado Profissional em Matemática, Estatística e Computação Aplicadas à Indústria) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2025.

ABSTRACT

Keywords: Ttag, tag, tag.

LISTA DE ILUSTRAÇÕES

Figura 1 – Exemplo do Padrão Físico Universal (51.5: Cor Abaixo da Média, Branco / Grau de Folhas 5)	37
Figura 2 – Equipamento Uster HVI 1000	40
Figura 3 – Gráfico de cores e classificação manual e instrumental de fibras de algodão. No eixo vertical, estão os valores de reflectância. Quanto maior o valor, mais brilhante é o algodão. No eixo horizontal, estão valores típicos do índice de amarelo. Quanto maior o valor, mais amarela é a amostra.	42
Figura 4 – Equipamento de coleta de amostras	54
Figura 5 – Fluxograma do processo de coleta de amostras e aquisição de imagens. . . .	55
Figura 6 – Matriz de confusão	64

LISTA DE QUADROS

LISTA DE ALGORITMOS

LISTA DE CÓDIGOS-FONTE

LISTA DE TABELAS

Tabela 1 – Códigos dos tipos de Cor, Classes de Cor ou Grau de Cor do Algodão Upland	39
Tabela 2 – Resumo comparativos das principais características entre sensores CCD e CMOS	44
Tabela 3 – Distribuição original de imagens (patches) por classe no dataset.	57
Tabela 4 – Resultados comparativos dos melhores execuções por modelo, otimizados para acurácia de validação.	62
Tabela 5 – Análise de desempenho por classe do modelo EfficientNet	62

LISTA DE SÍMBOLOS

SUMÁRIO

1	INTRODUÇÃO	29
2	REVISÃO DA LITERATURA	33
2.1	Agronegócio Brasileiro e o Algodão	33
2.1.1	<i>Agricultura no Brasil</i>	33
2.1.2	<i>A Cadeia Produtiva do Algodão</i>	34
2.2	Qualidade do algodão	34
2.2.1	<i>Contexto Histórico e Econômico</i>	35
2.2.2	<i>Métodos e Padrões de Classificação</i>	36
2.2.2.1	<i>A Classificação Visual e sua Subjetividade</i>	36
2.2.2.2	<i>A Classificação Instrumental (HVI) e suas Limitações</i>	40
2.2.2.3	<i>Relação entre Elas</i>	41
2.3	Visão Computacional Aplicada à Agricultura	42
2.3.1	<i>Fundamentos de um Sistema de Visão Computacional</i>	43
2.3.1.1	<i>Captura de imagens</i>	43
2.3.1.2	<i>Iluminação</i>	44
2.3.1.3	<i>Software</i>	45
2.3.2	<i>Processamento e análise de imagens</i>	45
2.3.3	<i>Aplicações da Visão Computacional no Agronegócio</i>	46
2.3.3.1	<i>Deteção de Doenças em Plantas</i>	47
2.4	Classificação Automatizada do Algodão com Visão Computacional	49
2.4.1	<i>Primeiras Abordagens e Desafios</i>	49
2.4.2	<i>O Advento do Aprendizado de Máquina</i>	49
2.4.3	<i>A Revolução do Aprendizado Profundo</i>	50
2.5	Arquiteturas de Aprendizado Profundo para Classificação de Imagens	50
2.5.1	<i>Redes Neurais Convolucionais Clássicas (VGGNet, Inception, ResNet)</i>	50
2.5.2	<i>Arquiteturas Modernas e Eficientes (EfficientNet)</i>	50
2.5.3	<i>O Paradigma dos Transformers (ViT, Swin-T)</i>	50
2.5.4	<i>A Evolução Híbrida (ConvNeXt)</i>	51
2.6	Síntese da Literatura e Lacunas da Pesquisa	51
3	METODOLOGIA	53

3.1	Desenvolvimento do Sistema de Aquisição de Dados (Caixa de Captura)	53
3.2	Protocolo de Coleta e Amostragem	54
3.3	Pré-processamento e preparação dos dados	56
3.4	Construção do Conjunto de Dados, Rotulagem e Balanceamento de Classes	56
3.5	Ambiente de treinamento e avaliação dos modelos	57
3.6	Desenho Experimental	58
3.7	Modelos Avaliados	58
3.7.1	<i>ResNet: Aprendizado Residual Profundo</i>	58
3.7.2	<i>EfficientNet: Compound Scaling Otimizado</i>	59
3.7.3	<i>VGGNet: Profundidade através da Simplicidade Arquitetural</i>	59
3.7.4	<i>Inception: Fatorização de Convoluções e Processamento Multi-escala</i>	60
3.7.5	<i>ViT</i>	60
3.7.6	<i>Swin-T</i>	60
3.7.7	<i>ConvNeXt</i>	60
4	RESULTADOS	61
4.1	Análise Comparativa Global	61
4.2	Análise de desempenho por classe	62
4.3	Análise qualitativa dos erros de classificação	62
5	DISCUSSÃO	65
6	CONCLUSÃO	67
REFERÊNCIAS		69
APÊNDICE A	APÊNDICE 1	77
ANEXO A	REPOSITÓRIO GIT	79

INTRODUÇÃO

O algodão (*Gossypium hirsutum* L.) representa uma das culturas de maior relevância econômica mundial, sendo conhecido como “ouro branco” devido ao seu impacto estratégico no agronegócio global. A fibra do algodão sustenta uma indústria têxtil avaliada em aproximadamente 600 bilhões de dólares anuais (KHAN *et al.*, 2020), consolidando sua posição como commodity essencial para a economia mundial. No contexto brasileiro, o país figura entre os principais produtores globais, com produção anual de aproximadamente 2,5 milhões de toneladas de pluma em área cultivada de 1,6 milhão de hectares (CONAB, 2024), o que reforça o seu papel fundamental na balança comercial nacional.

A classificação da qualidade das fibras constitui uma etapa crítica na cadeia produtiva e comercial do algodão, determinando diretamente o valor de mercado e o poder de negociação do produto (YAŞAR, 2021). O processo segue padrões internacionais que orientam a comercialização desde 1906, quando o Departamento de Agricultura dos Estados Unidos (USDA) criou o sistema de padronização que permanece como referência mundial. Atualmente o USDA mantém 15 categorias de classificação de algodão, que são atualizadas anualmente e servem como referência para as classificações visuais realizadas em diversos países (Cotton Incorporated, 2017).

No Brasil, este processo é regulamentado pela Instrução Normativa n. 24/2016 do Ministério de Estado da Agricultura, Pecuária e Abastecimento (MAPA), que traça padrões para a classificação, com requisitos de identidade e qualidade, amostragem e apresentação do produto (MAPA, 2016).

No processo produtivo do algodão a classificação é feita por amostragem, e pode ser realizada de duas formas: por método visual ou por método instrumental. A classificação visual é realizada por especialistas com base nos Padrões Físicos Universais, levando em conta a cor das fibras, a presença de impurezas (como folhas), as contaminações de matérias estranhas e o modo de preparação (beneficiamento) do produto. Apesar de ser uma abordagem mais ágil, ela incorpora um grau elevado de subjetividade inerente à interpretação humana, o que pode resultar

em variabilidade nos resultados e suscitar questionamentos durante negociações comerciais. Já a classificação instrumental é realizada por equipamento do tipo HVI (*High Volume Instrument*) e proporciona maior objetividade e reprodutibilidade. No entanto, essa técnica exige um tempo de análise consideravelmente maior, custos operacionais elevados, preparo específico das amostras e condições laboratoriais controladas (OLIVEIRA, 2022) (MAPA, 2016).

O principal gargalo logístico da cadeia produtiva ocorre na etapa de "emblocamento", que consiste na criação de blocos de algodão de aproximadamente 25 mil toneladas, compostos por fardos que possuem a mesma classificação (geralmente entre 110 e 125 fardos), sendo cada bloco é a menor unidade de comercialização. A dinâmica operacional das algodozeiras, funcionando continuamente 24 horas por dia durante a safra, exige velocidade nesse processo de "emblocamento". Por isso, as empresas optam por realizar esta etapa do processo de acordo com a classificação visual, já que os resultados da classificação por instrumentos podem demorar até 24 horas para chegar.

Mesmo com a classificação visual, que é mais rápida que a por instrumentos, existe um ponto de lentidão no processo, pois é necessário que as amostras sejam enviadas para as unidades de classificação e somente depois que o emblocamento é realizado. Ter as unidades de classificação dentro da indústria não se mostra viável pela necessidade de se ter um ambiente controlado para garantia da integridade das amostras.

Nesse cenário, um sistema automatizado que possa ser instalado diretamente na linha de produção, capaz de analisar cada fardo em tempo real, emerge como uma solução de alto impacto para a otimização do processo. Para enfrentar este desafio, a Visão Computacional se apresenta como a tecnologia mais adequada.

Trata-se da ciência responsável pela visão de uma máquina, pela forma como um computador enxerga o meio à sua volta, extraíndo informações significativas a partir de imagens capturadas por diversos dispositivos como câmeras, sensores, scanners, etc. Estas informações permitem reconhecer, manipular e pensar sobre os objetos que compõem uma imagem (BALLARD; BROWN, 1982).

Desde os primeiros estudos na área, na década de 1970, até os dias atuais, o campo evoluiu drasticamente, principalmente com o advento da Inteligência Artificial, permitindo que computadores executem tarefas visuais complexas com precisão próxima ou superior à humana. Assim, a visão computacional fornece ao computador uma infinidade de informações precisas a partir de imagens e vídeos, de forma que o computador consiga executar tarefas inteligentes, simulando e aproximando-se da inteligência humana (OLIVEIRA; HONORATO, 2024).

Um sistema básico de visão computacional consiste em quatro características: iluminação, câmera, computador e software de processamento de imagens. Esse sistema vai permitir a captura da imagem, sua conversão digital para armazenamento e processamento no computador e o software de processamento de imagens será responsável pelo aprimoramento, segmentação,

detecção ou classificação da imagem (ZHANG; LI, 2014a).

O sistema de iluminação deve ser capaz de destacar as características de interesse do objeto, em detrimento das demais características. É um sistema de extrema importância para se garantir a eficiência e a acurácia de um sistema de visão computacional, além de ter uma grande influência na qualidade das imagens. As chaves de um bom sistema de iluminação são aquelas que provêm uma iluminação uniforme com um espectro de características e que produzem imagens de alta qualidade (THOMASSON; SHEARER; BYLER, 2005a).

A câmera é o componente principal do sistema de visão computacional, que é usado para a aquisição da imagem e para a troca de dados com o computador. Existem diferentes tipos de dispositivos que capturam imagens em diversos espectros como monocromáticas, RGB, ultrassom, raios-x, NIR, etc (BROSNAN; SUN, 2002).

A automação da classificação visual por meio da visão computacional visa, portanto, substituir um processo manual e subjetivo por um sistema objetivo, rápido e padronizado, mitigando as incertezas que geram disputas comerciais. Diante deste cenário, justifica-se a construção de um sistema que realize a classificação do produto em conformidade com as regulamentações, mas eliminando a subjetividade e o gargalo logístico do processo. Este trabalho busca, portanto, responder à seguinte pergunta:

Até que ponto arquiteturas de aprendizado profundo, incluindo Redes Neurais Convolucionais e Transformers, podem automatizar a classificação visual do algodão em um ambiente industrial, equilibrando acurácia e eficiência computacional?

Assim, o objetivo geral deste trabalho é desenvolver e avaliar um sistema de visão computacional para a classificação automática do tipo de algodão, comparando o desempenho de arquiteturas CNN e Transformer. Para atingir este objetivo, foram definidos os seguintes objetivos específicos:

- Construir um dataset de imagens de algodão, capturadas sob iluminação controlada, representativo das classes de maior relevância comercial no cerrado brasileiro.
- Avaliar e comparar o desempenho de diferentes arquiteturas de aprendizado profundo (ResNet, VGGNet, Inception, EfficientNet, ViT, Swin-T e ConvNeXt) em termos de acurácia, F1-Score e matriz de confusão.
- Analisar a relação entre a complexidade computacional dos modelos (número de parâmetros e tempo de inferência) e sua eficácia na classificação, identificando a arquitetura com o melhor balanço para aplicação industrial.

Este trabalho está organizado em X capítulos. O Capítulo 2 apresenta uma revisão da literatura sobre a classificação de algodão e as arquiteturas de visão computacional. O Capítulo 3 detalha a metodologia... e assim por diante.

REVISÃO DA LITERATURA

Este capítulo tem como objetivo consolidar a linha de raciocínio fundamental para a elaboração dessa dissertação. Primeiramente será apresentado um panorama geral sobre o agronegócio brasileiro, com foco na cultura do algodão, abordando pontos como os principais desafios da produção, sua importância e seus destinos comerciais. Em seguida, detalha-se o processo de avaliação da qualidade do algodão, com ênfase nos padrões internacionais, regulamentações específicas no Brasil e os processos adotados na indústria. Na sequência, será contextualizado o tema dos sistemas de visão computacional, com aplicações no setor da agricultura, especialmente na classificação automatizada. Por fim, o capítulo discutirá o papel da inteligência artificial e os principais modelos empregados em sistemas de visão computacional, culminando na identificação da lacuna de pesquisa que este trabalho se propõe a preencher.

2.1 Agronegócio Brasileiro e o Algodão

2.1.1 Agricultura no Brasil

A agricultura brasileira já se consolidou como uma das maiores do mundo, fornecendo produtos essenciais para diversos setores da economia global, como a alimentação, a bioenergia, o setor têxtil entre outros. Essa consolidação é um reflexo de investimentos em inovações tecnológicas, que começaram com a terceira revolução agrícola (Revolução Verde) e se estendem até hoje com a disseminação da agricultura digital, integrando a agricultura de precisão e ferramentas como inteligência artificial para aumento da produtividade e sustentabilidade (ABBADÉ, 2014; BASSO; NEVES; SA, 2024).

O setor tem se destacado como um dos mais robustos, representando 23% da economia nacional (FILHO *et al.*, 2024), com exportações atingindo recordes históricos. Mesmo em cenários de queda nos preços das commodities e desafios climáticos, como a seca e fenômenos como o El Niño (LIN; QIAN, 2019) e desafios logísticos (GONÇALVES *et al.*, 2024), o Brasil

manteve o crescimento no valor total exportado. Em 2024, a expectativa é de que o país alcance US\$ 168,1 bilhões em exportações de produtos agrícolas, impulsionado por fatores como a desvalorização do real frente ao dólar, o que aumenta a competitividade dos produtos brasileiros no mercado internacional (CARDOSO *et al.*, 2024).

No contexto da produção agrícola brasileira, a tecnologia desempenhou um papel essencial na adaptação do país a diferentes tipos de culturas, permitindo o cultivo de variedades mais resistentes e otimizadas para o clima tropical (BASSO; NEVES; SA, 2024). Além disso, a introdução de biotecnologia e o avanço em estudos moleculares têm possibilitado o desenvolvimento de culturas com maior produtividade e resistência a pragas (DAS *et al.*, 2023), sendo o algodão (*Gossypium hirsutum*) um exemplo significativo e cuja produção se beneficia de tais avanços, como resistência genética e técnicas de cultivo adaptadas ao clima e solo brasileiros (RIBEIRO *et al.*, 2017; RIBEIRO *et al.*, 2019; RIBEIRO *et al.*, 2022).

2.1.2 A Cadeia Produtiva do Algodão

Em 2024 o Brasil se consolidou como o maior exportador mundial de algodão em volume. As condições climáticas favoráveis, aliadas ao aumento da demanda internacional, permitiram um crescimento expressivo das exportações brasileiras de algodão em 2024. A produção alcançou 3,2 milhões de toneladas, com a China como principal destino, e as exportações estão projetadas para somar US\$ 5,2 bilhões até o fim do ano, um aumento de 56% em relação ao ano anterior. Isso reflete o papel estratégico do algodão na pauta exportadora do agronegócio brasileiro, que vai além da alimentação, abrangendo setores como o têxtil e de bioenergia (CARDOSO *et al.*, 2024).

EXPLICAR MAIS EM DETALHES COMO FUNCIONA A CADEIA PRODUTIVA DO ALGODÃO

- Produção no Campo: Plantio, manejo e colheita (geralmente mecanizada). . .
- Beneficiamento (Algodoeira): Descaroçamento (separação da fibra e da semente), limpeza e prensagem dos fardos.
- Classificação: A etapa crítica de análise da qualidade (visual e/ou instrumental). É aqui que a dissertação se insere
- Armazenamento e Logística: Emblocamento e transporte para os portos ou indústria têxtil.

2.2 Qualidade do algodão

A classificação e a avaliação da qualidade do algodão são processos fundamentais para a cadeia de produção e comércio dessa fibra, influenciando diretamente o valor de mercado e a

adequação às diversas aplicações industriais. Nesta seção será examinado o histórico, os critérios de classificação e as normas internacionais, com destaque para o sistema estadunidense, além das especificidades regulatórias no Brasil.

2.2.1 Contexto Histórico e Econômico

A prática sistemática de classificação do algodão remonta do início do século XIX, tendo como origem na cidade de Liverpool na Inglaterra. A implementação dessa prática foi necessária devido à modernização das máquinas de fiar, impulsionada na primeira revolução industrial, onde se observou que a eficiência na produção de fios era maior dependendo da qualidade da fibra, gerando assim mais lucro para o fiador (MORAIS *et al.*, 2021). As transações comerciais da fibra do algodão passaram então a levar em conta sua qualidade, porém dependendo do setor envolvido (produtor ou fiador) a percepção sobre a qualidade da fibra mudava. Assim, foram desenvolvidos padrões para unificar e facilitar a comercialização da fibra. Nesse contexto, a criação de uma terminologia padronizada e de critérios objetivos de avaliação tornou-se essencial para a negociação e, especialmente, para garantir uma base de comparação justa que facilitasse as transações internacionais (EARLE; DEAN, 1914).

Conforme abordado por Conant (1915), a adoção do *United States Cotton Futures Act* pela Bolsa de Algodão de Nova York, que reformou as práticas de contratos futuros de algodão após pressões significativas, incluindo uma ameaça de imposto proibitivo. A principal mudança introduzida foi a substituição de um sistema arbitrário de fixação de diferenças de preço entre diferentes tipos de algodão por um sistema baseado nas diferenças comerciais reais do mercado à vista. Esse novo sistema visava alinhar melhor os contratos futuros com a realidade do mercado, evitando distorções que prejudicavam tanto a proteção de *hedge* quanto a confiança no mercado. O ato também introduziu medidas de identificação por tipo para os fardos entregues em contrato e a supervisão direta do governo, trazendo mais transparência e equidade ao processo de negociação.

Earle e Dean (1914) também trazem que nos Estados Unidos, o sistema oficial de classificação foi desenvolvido no início do século XX, com a contribuição de produtores, especialistas e representantes do governo, resultando na formulação de nove padrões oficiais estabelecidos pelo Departamento de Agricultura (USDA). Na década de 1960 o USDA iniciou as pesquisas para desenvolver métodos instrumentais de classificação, que culminaram na adoção da classificação por HVI (*High Volume Instrument*) praticamente em toda a produção americana de algodão (KNOWLTON, 2005). Atualmente, apenas em casos especiais e identificação de corpos estranhos que o algodão é classificado de forma manual, porém pesquisas continuam sendo desenvolvidas para que a classificação instrumental contemple todos os aspectos avaliados (INCORPORATED, 2020).

2.2.2 Métodos e Padrões de Classificação

No Brasil, o procedimento para a classificação da pluma do algodão é estabelecido pela Instrução Normativa n. 24 de 2016 do Ministério da Agricultura e leva em consideração Padrões Físicos Universais, como a cor da fibra, a presença de folhas e impurezas, contaminação de matérias estranhas e o modo de beneficiamento do produto (MAPA, 2016).


Tem início com o processo de amostragem, que leva em consideração os seguintes pontos:

- A amostra pode ser realizada manualmente ou mecanicamente;
- De cada fardo deve-se extrair duas amostras de lados opostos (no mínimo 150 gramas cada). Cada uma dessas amostras será dividida no sentido longitudinal e essa metade adicionada à metade da outra amostra, formando assim duas amostras de trabalho. Uma será enviada para classificação visual e outra para classificação instrumental;
- As amostras devem ser manuseadas e acondicionadas em pacotes de forma a não descaracterizá-las ao longo do processo;
- O tamanho das amostras deve ter no mínimo 25 a 30 centímetros de comprimento, 13 a 15 centímetros de largura e 8 a 13 centímetros de espessura;

2.2.2.1 A Classificação Visual e sua Subjetividade

Após, uma das amostras retiradas seguem para o processo de classificação visual. Neste processo é utilizado como referência os Padrões Físicos Universais, que consistem em caixas com 6 amostras de algodão, tendo como base os padrões americanos para os algodões "Upland" e "Pima", conforme exemplo na Figura 1.

Figura 1 – Exemplo do Padrão Físico Universal (51.5: Cor Abaixo da Média, Branco / Grau de Folhas 5)



Fonte: Do Autor

A classificação do algodão é feita com base em tipos de cor e graus de folha, ambos representados por códigos que correspondem aos Padrões Físicos Universais. A Tabela 1 apresenta esses tipos de cor e suas respectivas classes. O grau de folha é uma escala que varia de 1 a 8, determinada pela quantidade de folhas presentes na amostra. Esses padrões devem ser visualizados e memorizados antes de iniciar a classificação, podendo ser consultados sempre que necessário.

Após a memorização dos padrões, as amostras devem ser divididas no sentido longitudinal ao meio, subdividindo as metades com cuidado para não descaracterizá-las durante o manuseio. As duas piores partes são selecionadas para análise, sendo a pior parte voltada para cima, para facilitar a análise.

Avalia-se a cor, brilho, manchas, impurezas, contaminações e defeitos de beneficiamento. A determinação do tipo é feita com base no Tipo de Cor e Grau de Folhas e o resultado é registrado no Laudo de Classificação. Esse método considera principalmente o grau de cor, determinado pela combinação de matiz, saturação e brilho das fibras; o nível de folha, que quantifica a presença de materiais vegetais não fibrosos; os caracteres de preparação, que indicam deficiências no beneficiamento; e a presença de contaminações por materiais estranhos (ABBADÉ, 2014)

Apesar da rapidez relativa do processo a classificação visual do algodão apresenta limitações inerentes à subjetividade do julgamento humano. Conforme destacado por (MATUSIAK;

WALAWSKA, 2010), a avaliação organoléptica realizada por classificadores humanos treinados é influenciada por fatores individuais e pode ser inadequada para atender plenamente às necessidades da indústria têxtil, especialmente no que diz respeito à previsibilidade do comportamento das fibras durante o processamento. Os autores ressaltam que “a avaliação humana é subjetiva e inadequada às necessidades dos consumidores, especialmente na previsão do comportamento da fibra no processamento do algodão” e que a análise visual, mesmo sob condições controladas de iluminação e com o uso de padrões físicos, está sujeita à variabilidade entre avaliadores e à dificuldade de distinção precisa entre categorias próximas de cor. Esse cenário reforça a necessidade de métodos mais objetivos e reprodutíveis para a avaliação da cor do algodão, como os sistemas instrumentais atualmente em desenvolvimento e adoção em escala global.

Tabela 1 – Códigos dos tipos de Cor, Classes de Cor ou Grau de Cor do Algodão Upland

	Branco	Ligeiramente Creme	Creme	Avermelhado	Amarelado
Cor Boa Média - GM (Good Middling)	11	12	13	-	-
Cor Estritamente Média-SM (Strict Middling)	21	22	23	24	25
Cor Média-M (Middling)	31	32	33	34	35
Cor Estritamente Abaixo da Média-SLM (Strict Low Middling)	41	42	43	44	-
Cor Abaixo da Média-LM (Low Middling)	51	52	53	54	-
Cor Estritamente Boa Comum-SGO (Strict Good Ordinary)	61	62	63	-	-
Cor Boa Comum-GO (Good Ordinary)	71	-	-	-	-
Abaixo de Padrão	81	82	83	84	85

2.2.2.2 A Classificação Instrumental (HVI) e suas Limitações

Em paralelo a segunda amostra é enviada para a classificação instrumental, que é realizada em laboratório. O ambiente de trabalho deve atender a condições específicas de umidade e temperatura. As amostras devem estar em bandejas teladas ou perfuradas em uma única camada para garantir circulação de ar.

São utilizados equipamentos do tipo HVI (*High Volume Instrument*), que devem estar calibrados conforme as especificações do fabricante. Na Figura 2, é apresentado o modelo Uster HVI1000, que realiza a análise do HVI.

Figura 2 – Equipamento Uster HVI 1000



Fonte: (Uster Technologies, 2024)

O processo de análise consiste na análise de micronaire, que é feita em um corpo de prova, enquanto os outros parâmetros são analisados em dois corpos de prova por amostra. A amostra é submetida ao equipamento HVI para obtenção do relatório. O resultado é analisado e um documento de classificação é gerado.

Os parâmetros analisados são:

- Comprimento da Fibra (UHML): Comprimento médio da metade superior das fibras.
- Índice de Uniformidade do Comprimento da Fibra (%UI): Relação entre o comprimento médio total das fibras e o comprimento médio das fibras mais longas.
- Resistência ou Tenacidade da Fibra (Str): Medida da força necessária para romper as fibras, expressa em gf/tex.
- Alongamento à Ruptura da Fibra (%Elg): Percentual de extensão que a fibra suporta antes de romper.

- Micronaire da Fibra (Mic): Combinação de finura e maturidade da fibra.
- Grau de Reflectância (%Rd): Nível de luminosidade e cor branca refletida pelas fibras.
- Grau de Amarelamento (+b): Índice que expressa o nível de amarelamento da fibra.
- Índice de Fibras Curtas (%SFI): Percentual de fibras com comprimento inferior a 0,50 polegadas.
- Índice de Consistência da Fiação (SCI): Valor calculado com base nas propriedades físicas das fibras e sua correlação com a performance de fiação.


Embora ofereça maior objetividade e repetibilidade comparada à classificação visual, a classificação instrumental apresenta limitações operacionais significativas. Os equipamentos HVI requerem investimentos substanciais, com custos de aquisição e manutenção elevados, necessidade de ambiente climatizado controlado, calibração periódica com padrões de algodão certificados pelo USDA, e pessoal técnico especializado para operação (BRAZIL, 2021). Adicionalmente, o tempo de análise e os requisitos de preparo específico das amostras podem gerar gargalos em operações industriais de alto volume, especialmente quando resultados rápidos são necessários para decisões operacionais imediatas.

2.2.2.3 Relação entre Elas

Nickerson e Newton (1958) chegaram à relação entre a reflectância (%Rd) e o índice de amarelo (+b) com a classificação do algodão por meio de um estudo detalhado que utilizou o Colorímetro Nickerson-Hunter. Este instrumento mede a cor do algodão em termos destes dois atributos, permitindo uma representação em um gráfico bidimensional. Para converter essas medidas em uma classificação de cor única, os autores desenvolveram um índice que relaciona os valores medidos com os padrões oficiais de tipo de algodão.

A análise envolveu encontrar uma linha de melhor ajuste entre os dados medidos e os padrões de cor, utilizando métodos de regressão para obter fórmulas de conversão e diagramas que facilitassem essa associação (Figura 3). Essa abordagem permitiu criar índices numéricos para diferentes estados do algodão, como fibras em estado bruto e fios tingidos, mantendo o valor de *Middling* (Cor Média) em 100 e ajustando as relações para outros graus de cor.

Figura 3 – Gráfico de cores e classificação manual e instrumental de fibras de algodão. No eixo vertical, estão os valores de reflectância. Quanto maior o valor, mais brilhante é o algodão. No eixo horizontal, estão valores típicos do índice de amarelo. Quanto maior o valor, mais amarela é a amostra.



Fonte: [Cotton Incorporated \(2024\)](#)

2.3 Visão Computacional Aplicada à Agricultura

Nesta sessão será explorada com mais profundidade a disciplina de visão computacional, os sistemas de visão computacional e seus conceitos fundamentais, o processamento de imagens e aplicação da visão computacional no agro, com ênfase nas tecnologias e métodos aplicados à cultura do algodão.

[Oliveira e Honorato \(2024\)](#) descrevem o histórico da visão computacional como uma ciência recente, cuja primeira menção foi em 1955, com a ideia de equipar computadores com "olhos e ouvidos". Na década de 1970, os primeiros estudos combinaram visão computacional

com inteligência artificial, acreditando que a emulação da visão humana por máquinas seria rapidamente alcançada. Destaque para [Marr \(1976\)](#) que, dentro do campo da neurofisiologia, desenvolveu uma abordagem computacional para a visão, que consistia na formulação de um algoritmo para interpretação visual em qualquer contexto físico. Seus estudos foram um dos principais pontos de partida para as pesquisas em visão computacional ([VAINA, 2004](#)).

No entanto, descobriu-se que a complexidade era maior do que imaginado, devido à falta de informações sobre a interpretação de imagens pelo cérebro humano, levando a avanços progressivos nas décadas seguintes ([OLIVEIRA; HONORATO, 2024](#)), resultando na consolidação da visão computacional como a disciplina que busca desenvolver métodos e algoritmos para que os computadores possam interpretar e entender imagens de forma semelhante à percepção humana ([BALLARD; BROWN, 1982](#)).

2.3.1 Fundamentos de um Sistema de Visão Computacional

[Saldaña et al. \(2013\)](#) discute que os sistemas de visão computacional são projetados para extrair e analisar informações de objetos de forma automática e objetiva, sendo rápidos, consistentes e não invasivos. Esses sistemas geralmente consistem em um dispositivo de captura de imagens, dispositivo de iluminação e um computador que processa as imagens capturadas.

2.3.1.1 Captura de imagens

Existem diferentes sensores que podem ser utilizados para gerar uma imagem, como ultrassom, raios-X, sensores térmicos, sensores de espectroscopia de infravermelho próximo (NIR) e câmeras tradicionais, estas geralmente mais utilizadas em problemas de visão computacional ([BROSAN; SUN, 2004](#)).

As câmeras são responsáveis pela captura da imagem, que é então convertida em sinais eletrônicos e processada. Basicamente, existem dois tipos de sensores: as câmeras CCD (*Charge-Coupled Device*) e CMOS (*Complementary Metal-Oxide-Semiconductor*).

As câmeras CCD são reconhecidas pela alta qualidade de imagem que oferecem, especialmente em condições de baixa iluminação. Isso ocorre devido ao menor ruído intrínseco de seus sensores, que apresentam substratos mais silenciosos e menor quantidade de circuitos integrados no chip. Além disso, os sensores CCD possuem maior faixa dinâmica, proporcionando uma melhor relação entre os níveis de saturação e o limite inferior de sinal detectável, o que resulta em imagens mais detalhadas e com melhor gradação tonal. Outra vantagem significativa das câmeras CCD é a uniformidade na resposta dos pixels, o que as torna ideais para aplicações que exigem alta precisão, como fotografia científica, televisores de alta performance e aplicações médicas. No entanto, essa tecnologia apresenta desvantagens como maior consumo de energia e tamanho físico do sistema, já que muitas funções do sensor dependem de circuitos externos ([LITTWILLER, 2001](#)).

Os sensores CMOS evoluíram significativamente nas últimas décadas, consolidando-se como uma alternativa viável aos CCDs, especialmente em aplicações que demandam baixo custo, baixo consumo de energia e integração de múltiplas funcionalidades em um único chip. A arquitetura CMOS permite a integração de circuitos analógicos e digitais diretamente no sensor, resultando em sistemas menores e mais leves. Além disso, sensores CMOS consomem menos energia, podendo operar com uma única fonte de baixa tensão, o que os torna ideais para dispositivos móveis e portáteis. Apesar dessas vantagens, os CMOS ainda enfrentam desafios como menor sensibilidade, maior ruído em condições de baixa iluminação e menor faixa dinâmica (BIGAS *et al.*, 2006). Na Tabela 2 é apresentado um resumo comparando as principais características dos sensores CCD e CMOS, apresentados por Bigas *et al.* (2006).

Tabela 2 – Resumo comparativos das principais características entre sensores CCD e CMOS

Característica	CCD	CMOS
Consumo de energia	Alto	Baixo
Custo	Alto	Baixo
Integração em chip	Não	Sim
Flexibilidade	Limitada	Alta
Faixa dinâmica	Alta	Limitada
Sensibilidade	Alta	Limitada
Ruído	Baixo	Alto
Qualidade de imagem	Alta	Limitada
Velocidade	Limitada	Alta
Tamanho físico do sistema	Maior	Menor
Aplicações	Alta qualidade, ciências	Dispositivos móveis, segurança

Fonte: Bigas *et al.* (2006)

FALAR AQUI SOBRE FORMA DE TRANSMITIR IMAGENS E COMPACTAÇÃO PNG/BMP e JPG (lossless e lossy / para análise científica, formatos lossless são preferíveis para evitar artefatos que possam ser mal interpretados pelo modelo, mas que JPG é comum na prática por sua eficiência de armazenamento.)

2.3.1.2 Iluminação

A iluminação desempenha um papel essencial nos sistemas de visão computacional, pois define as propriedades ópticas dos objetos a serem analisados. A luz incidente pode ser absorvida, refletida ou transmitida, influenciando diretamente a qualidade das imagens capturadas. Para otimizar o desempenho do sistema de visão, a escolha e a configuração do sistema de iluminação devem ser adaptadas à aplicação específica. Essa seleção cuidadosa reduz a necessidade de etapas complexas de processamento de imagem, aumentando a eficiência e a precisão das análises (CHEN; CHAO; KIM, 2002).

Zhang e Li (2014a) destacam a importância de fontes de luz que realcem as características dos objetos e permitam distinções claras entre as partes detectadas e outras áreas. A eficiência

e a precisão de um sistema de visão computacional dependem significativamente da qualidade da iluminação, que deve fornecer luz uniforme e estável, além de evitar reflexos e sombras que possam comprometer a análise.

A escolha da iluminação ideal depende das características espectrais desejadas para a aplicação, considerando tanto a geometria do objeto quanto os atributos a serem destacados. Por exemplo, sistemas que utilizam luz difusa são eficazes para minimizar reflexos especulares, enquanto a iluminação traseira pode ser essencial para delinear contornos e aumentar o contraste em objetos translúcidos. Diferentes tipos de lâmpadas são utilizados, incluindo tubos de raios X, fluorescentes, incandescentes, lasers e lâmpadas de infravermelho, cada uma operando em faixas espectrais específicas, desde raios X (0,01-10 nm) até o infravermelho próximo (700-2500 nm). Enquanto as lâmpadas fluorescentes são preferidas para análises baseadas em luz visível, os LEDs têm ganhado destaque por sua estabilidade, baixo consumo de energia e ampla disponibilidade em comprimentos de onda específicos (CUBERO *et al.*, 2010).

2.3.1.3 Software

FALAR SOBRE O COMPONENTE DO SOFTWARE (Software é a "inteligência" do sistema, responsável por orquestrar a captura e, principalmente, por implementar os algoritmos de processamento e análise de imagem, conctando com a próxima seção. Falar da libs como OpenCV, Scikit-Image e frameworks de deep learning como PyTorch e TensorFlow, para conctar com a metodologia)

2.3.2 Processamento e análise de imagens

O processamento e a análise das imagens são componentes fundamentais nos sistemas de visão computacional, desempenhando um papel crucial na extração de informações visuais úteis para a classificação, detecção de defeitos e avaliação de qualidade (KRUTZ *et al.*, 2000).

Segundo Brosnan e Sun (2002), o processamento de imagens engloba operações destinadas a melhorar a qualidade das imagens capturadas, removendo ruídos, corrigindo distorções geométricas e uniformizando a iluminação. Essas etapas iniciais são essenciais para garantir que as imagens estejam adequadamente preparadas para a análise subsequente. Já a análise de imagens refere-se à segmentação e à extração de características dos objetos de interesse, como forma, cor e textura, permitindo a interpretação e o reconhecimento dos elementos nas imagens.

O processamento/análise de imagens é frequentemente dividido em três níveis: o processamento de baixo nível, que inclui a aquisição e o pré-processamento de imagens; o processamento de nível intermediário, focado na segmentação, representação e descrição; e o processamento de alto nível, que envolve o reconhecimento e a interpretação de padrões (GUNASEKARAN, 1996; SUN, 2000).

A aquisição consiste na conversão do sinal eletrônico do sensor para uma forma numérica.

O pré-processamento refere-se ao processamento inicial dos dados brutos da imagem para correção de distorções geométricas, remoção de ruídos, correção do nível de cinza e correção de desfoque (SHIRAI, 1987). O objetivo dessa etapa é melhorar a qualidade da imagem, removendo distorções indesejadas ou destacando características de interesse.

No nível intermediário, a segmentação de imagens é uma das etapas mais importantes em toda a técnica de processamento de imagens, pois os dados extraídos posteriormente dependem fortemente da precisão dessa operação. Seu principal objetivo é dividir uma imagem em regiões que possuam uma forte correlação com objetos ou áreas de interesse. A segmentação pode ser realizada por três técnicas diferentes: limiarização, segmentação baseada em bordas e segmentação baseada em regiões. A representação se refere à maneira como a forma ou estrutura de um objeto é modelada e armazenada, seja por contornos, áreas, momentos ou outras técnicas que traduzem os dados visuais para formatos matemáticos ou computacionais. Descrição, por sua vez, é o processo de derivar atributos ou características mensuráveis a partir dessa representação, como tamanho, forma, textura ou relações espaciais, que podem ser usadas para classificação, reconhecimento ou análise mais profunda (SONKA; HLAVAC; BOYLE, 1993).

O processamento de alto nível envolve o reconhecimento e interpretação de padrões, que visam a transformação de dados visuais em informações compreensíveis. Sonka, Hlavac e Boyle (1993) trazem também que o reconhecimento de padrões refere-se à identificação de objetos ou estruturas em uma imagem com base em suas características distintivas, utilizando métodos como aprendizado estatístico, redes neurais, e técnicas sintáticas para classificar ou agrupar dados visuais. Já a interpretação de padrões vai além, envolvendo o uso de conhecimento contextual e estratégias hierárquicas para compreender o significado dos objetos reconhecidos e suas relações no ambiente analisado.

2.3.3 Aplicações da Visão Computacional no Agronegócio

A visão computacional tem desempenhado um papel fundamental no agronegócio, sendo aplicada em áreas como classificação de culturas, detecção de doenças, monitoramento de qualidade, automação de processos e muito mais. A seguir, apresentam-se os principais estudos categorizados por aplicação.

A visão computacional consolidou-se como uma tecnologia disruptiva na agricultura, automatizando processos de inspeção para otimizar a produção e a qualidade de forma objetiva, rápida e em larga escala (PATRÍCIO; RIEDER, 2018; TIAN *et al.*, 2020).

A evolução tecnológica é o pilar desta transformação. A aquisição de imagens avançou de câmeras CCD convencionais para sensores hiperespectrais, de polarização e de luz estruturada, capazes de detectar características invisíveis ao olho humano, como defeitos internos em frutas (ZHU *et al.*, 2024; WANG *et al.*, 2023). Paralelamente, os algoritmos de análise migraram da extração manual de características morfológicas e de textura (ZAYAS *et al.*, 1996) para o

aprendizado profundo (*Deep Learning*). Redes Neurais Convolucionais (CNNs) e arquiteturas como YOLOv8 automatizam a identificação de padrões complexos, enquanto o aprendizado por transferência (*transfer learning*) acelera o desenvolvimento de modelos precisos mesmo com dados limitados (AHAD *et al.*, 2023; RAMOS *et al.*, 2024).

Esses avanços têm resultado em aplicações consolidadas em diversas frentes da agricultura. A classificação de grãos, sementes e fibras, como o trigo e o algodão, é uma das áreas mais desenvolvidas, nas quais a visão computacional substitui a gradação manual, aumentando a consistência e a eficiência do processo (UTKU, 2000; CHENG *et al.*, 1999). Na proteção de cultivos, a tecnologia tem papel fundamental na detecção precoce de doenças, pragas e plantas daninhas, sendo uma ferramenta essencial para a pulverização seletiva no contexto da agricultura de precisão (SHWETHA; BHAGWAT; LAXMI, 2024; JUWONO *et al.*, 2023). Já no monitoramento de lavouras, Veículos Aéreos Não Tripulados (VANTs) equipados com câmeras avançadas são empregados para estimar a produção, realizar a contagem de frutos e executar a fenotipagem em larga escala (LU *et al.*, 2015)

2.3.3.1 Detecção de Doenças em Plantas

Uma das aplicações mais consolidadas da visão computacional na agricultura é a detecção precoce de doenças. Estudos recentes demonstram a alta eficácia de Redes Neurais Convolucionais (CNNs) para esta tarefa, com trabalhos como o de Ahad *et al.* (2023) atingindo mais de 98% de acurácia na identificação de doenças em folhas de arroz. Arquiteturas ainda mais especializadas, como o modelo DeepRice proposto por Ritharson *et al.* (2023), alcançam precisão próxima de 100%, evidenciando a maturidade da área. A tendência atual, como aponta Shwetha, Bhagwat e Laxmi (2024), é a otimização desses modelos para implementação em dispositivos móveis, permitindo o diagnóstico diretamente no campo. O sucesso dessas abordagens é frequentemente potencializado pelo uso de aprendizado por transferência (*transfer learning*), que permite adaptar modelos pré-treinados para a tarefa específica de classificação de doenças foliares com maior eficiência (PAYMODE; MALODE, 2022). A fronteira da pesquisa na área já explora a comparação entre CNNs e Transformers, buscando determinar qual paradigma oferece o melhor desempenho para diferentes tipos de culturas e sintomas (DING *et al.*, 2024). Vale ressaltar que o sucesso de todos esses métodos de aprendizado profundo depende de etapas de pré-processamento robustas, como a segmentação precisa da área de interesse da imagem, uma área onde algoritmos clássicos baseados em saliência visual, como os de Zhu *et al.* (2024), estabeleceram fundamentos importantes.

Além da detecção precoce de doenças, a visão computacional é uma ferramenta fundamental para o monitoramento em campo e a estimativa de produtividade. Uma aplicação direta é a contagem de frutos, onde Veículos Aéreos Não Tripulados (VANTs) equipados com câmeras de alta resolução capturam imagens que são processadas por detectores de objetos modernos. O trabalho de Jiang *et al.* (2024), por exemplo, emprega a arquitetura YOLOv8 para a detecção e

contagem de melancias com alta precisão. Trazendo a aplicação para o contexto deste trabalho, [Singh et al. \(2023\)](#) desenvolveram algoritmos leves, otimizados para eficiência, com o objetivo de identificar os capulhos de algodão ("bolas de algodão") em tempo real, uma tarefa essencial para a colheita automatizada. A automação agrícola também se beneficia da visão computacional para a navegação de robôs autônomos, onde modelos de segmentação como a U-Net são utilizados para identificar as linhas de cultivo, permitindo que o maquinário se desloque pelo campo com precisão sem danificar as plantas ([GUO et al., 2024](#)).

A avaliação de qualidade de produtos já colhidos é uma das aplicações mais antigas e maduras da visão computacional. Abordagens pioneiras, como a de [Majumdar e Jayas \(1999\)](#), já demonstravam no final da década de 1990 a capacidade de classificar diferentes tipos de cereais com 100% de acurácia utilizando técnicas de análise de textura. De forma similar, [Utku \(2000\)](#) aplicaram métodos de seleção de características (feature selection) para discriminar variedades de trigo, consolidando o uso de visão computacional para garantir a qualidade e a padronização de grãos. Mais recentemente, a evolução da tecnologia permitiu ir além da simples classificação de variedades, focando na detecção de defeitos sutis. [Zhu et al. \(2024\)](#), por exemplo, desenvolveram um sistema baseado em luz estruturada, uma técnica de aquisição de imagem 3D, para identificar danos e machucados em maçãs com um IoU superior a 91%, uma tarefa consideravelmente mais complexa e de grande valor para a indústria alimentícia.

Garantir a pureza do produto agrícola, tanto no campo quanto no pós-colheita, é outra área de grande impacto da visão computacional. No contexto do algodão, a detecção de contaminantes é um problema clássico, extensivamente revisado por [Zhang e Li \(2014b\)](#). Soluções modernas para este desafio empregam detectores de objetos de aprendizado profundo; [Wang et al. \(2023\)](#), por exemplo, implementaram a arquitetura YOLOv5 para identificar fibras e materiais estranhos no algodão com alta velocidade e precisão. No campo, a pureza da lavoura é mantida pela remoção de plantas daninhas, uma tarefa que pode ser automatizada por sistemas de pulverização seletiva. Esses sistemas dependem de algoritmos de visão para diferenciar as plantas de interesse das invasoras, um tópico revisado por [Juwono et al. \(2023\)](#). A eficácia dessa abordagem é demonstrada por trabalhos como o de [Subeesh et al. \(2022\)](#), que alcançaram 97,7% de precisão na identificação de ervas daninhas utilizando a conhecida arquitetura InceptionV3. A visão computacional pode, ainda, ser estendida para a segurança ambiental da fazenda, com modelos como o YOLOv8 sendo adaptados para detectar focos de fumaça e incêndios florestais ([RAMOS et al., 2024](#)).

A integração da visão computacional em sistemas autônomos e a consolidação do conhecimento da área são temas recorrentes na literatura. Os fundamentos da robótica agrícola, como o uso de sistemas de visão global para a navegação de robôs, foram estabelecidos por trabalhos como o de [Klancar et al. \(2004\)](#). Hoje, aplicações avançadas se estendem à pecuária de precisão, onde o modelo Mask R-CNN, por exemplo, é utilizado para segmentar a imagem de suínos e prever seu peso sem contato físico, otimizando o manejo ([XIE et al., 2024](#)). A

vasta quantidade de pesquisas na área é periodicamente sintetizada em artigos de revisão, que mapeiam o estado da arte. [Patrício e Rieder \(2018\)](#) revisaram o uso de visão computacional no monitoramento de grãos, enquanto [Chuquimarca, Vintimilla e Velastin \(2024\)](#) focaram na classificação de frutas com o uso de dados hiperespectrais, uma modalidade de sensor que captura informações invisíveis ao olho humano. De forma mais ampla, [Ghazal, Munir e Qureshi \(2024\)](#) discutem como os dados extraídos por VANTs podem ser integrados a mapas de precisão para otimizar as estratégias de manejo em toda a propriedade agrícola.

2.4 Classificação Automatizada do Algodão com Visão Computacional

No contexto da classificação do algodão, a visão computacional oferece uma solução promissora para automatizar esse processo, superando as limitações dos métodos tradicionais. A pesquisa na área evoluiu significativamente, partindo do tratamento de incertezas nas classes de cor para a implementação de modelos avançados de aprendizado profundo (*deep learning*).

2.4.1 Primeiras Abordagens e Desafios

Inicialmente, uma das principais críticas aos sistemas instrumentais, como o HVI, era a dificuldade em lidar com as transições graduais e pouco definidas entre as classes de cor do algodão. Essas fronteiras, muitas vezes difusas, não são bem captadas por algoritmos convencionais, o que pode comprometer a precisão da classificação. Para contornar esse problema, estudos pioneiros, como o de [\(XU; DALE; HUANG, 2002\)](#), introduziram o uso de lógica fuzzy, permitindo a modelagem de incertezas e uma maior aproximação à percepção humana. Essa abordagem tornou os sistemas mais flexíveis e eficazes na identificação das nuances de cor presentes nas amostras de algodão.

Outro desafio central é a interferência de impurezas (*trash*) e sombras na medição da cor do algodão. Trabalhos como os de Thomasson et al. ([THOMASSON; SHEARER; BYLER, 2005b](#)) e Heng et al. ([HENG et al., 2020](#)) demonstraram que esses elementos afetam negativamente as medições de reflectância (Rd). Para contornar isso, desenvolveram-se algoritmos de segmentação para isolar digitalmente as impurezas, evoluindo de técnicas baseadas em limiares de cor (Otsu) para operadores de borda (Canny) e, mais recentemente, redes neurais como YOLO V5 para identificar e classificar diferentes tipos de impurezas em tempo real ([ZHANG; LI; LI, 2022](#)).

2.4.2 O Advento do Aprendizado de Máquina

As primeiras abordagens de classificação do algodão utilizavam características extraídas manualmente (cor, forma, textura) para alimentar classificadores de aprendizado de máquina,

como Support Vector Machine (SVM), alcançando acurácias em torno de 92% na detecção de fibras estranhas (YANG *et al.*, 2011).

2.4.3 A Revolução do Aprendizado Profundo

Com a ascensão do *deep learning*, as Redes Neurais Convolucionais (CNNs) passaram a dominar, automatizando a extração de características e melhorando a performance. Lv *et al.* (LV *et al.*, 2020) mostraram que, ao identificar impurezas previamente, a acurácia da classificação com VGGNet atingiu 98,9%. Mais recentemente, Fisher *et al.* (FISHER *et al.*, 2023) utilizaram uma gama de modelos (ANN, Random Forest, SVM) e introduziram a variância de cor intra-amostra como uma característica relevante, destacando a complexidade da tarefa e as limitações impostas pela subjetividade da rotulagem manual.

2.5 Arquiteturas de Aprendizado Profundo para Classificação de Imagens

2.5.1 Redes Neurais Convolucionais Clássicas (VGGNet, Inception, ResNet)

A evolução das arquiteturas de redes neurais convolucionais (CNNs) tem seguido uma trajetória marcada por crescente sofisticação e eficiência. A VGGNet, por exemplo, consolidou princípios de design modular e evidenciou as vantagens do uso de filtros convolucionais pequenos, o que simplificou a estrutura da rede e melhorou o desempenho (SIMONYAN; ZISSERMAN, 2014a). Um marco importante ocorreu com a introdução das conexões residuais na ResNet, que permitiram o treinamento de redes muito profundas ao mitigar o problema do desaparecimento do gradiente (*vanishing gradient*) (HE *et al.*, 2016). Posteriormente, a família Inception contribuiu com a ideia de processamento em múltiplas escalas por meio de módulos que operam paralelamente com diferentes tamanhos de filtros, ampliando a capacidade de extração de padrões (SZEGEDY *et al.*, 2016).

2.5.2 Arquiteturas Modernas e Eficientes (EfficientNet)

Já a EfficientNet propôs uma estratégia de escalonamento composto, otimizando simultaneamente a profundidade, largura e resolução da rede, o que resultou em um equilíbrio mais eficaz entre acurácia e custo computacional (TAN; LE, 2019).

2.5.3 O Paradigma dos Transformers (ViT, Swin-T)

Em um desvio radical da abordagem convolucional que dominou a visão computacional por quase uma década, pesquisadores começaram a explorar arquiteturas baseadas puramente

em mecanismos de atenção, inspiradas no sucesso dos Transformers em Processamento de Linguagem Natural. A ideia central é substituir as convoluções, que operam em vizinhanças locais, por um mecanismo de auto-atenção que pode modelar relações entre todos os pixels (ou patches) de uma imagem simultaneamente, capturando dependências de longo alcance de forma mais eficaz.

O primeiro trabalho a demonstrar a viabilidade desta abordagem foi o Vision Transformer (ViT)...

Apesar de seu sucesso, o ViT apresentava um custo computacional quadrático em relação ao número de patches, tornando-o ineficiente para imagens de alta resolução. Para resolver essa limitação, o Swin Transformer (Swin-T) foi proposto... [aqui você explica a inovação das janelas deslocadas do Swin-T]. Essa arquitetura hierárquica não só reduziu o custo computacional, mas também reintroduziu um viés indutivo local, combinando o melhor dos dois mundos.

2.5.4 A Evolução Híbrida (ConvNeXt)

Como o ConvNeXt "modernizou" a CNN? Ele "emprestou" a ideia dos Transformers, como: (1) o uso de convoluções de maior profundidade (depthwise convolutions), (2) o design de bloco invertido, e (3) kernels maiores (7x7). Importante destacar que ele representa uma síntese, provando que a arquitetura convolucional ainda é extremamente competitiva.

2.6 Síntese da Literatura e Lacunas da Pesquisa

Vimos que a classificação do algodão é um gargalo, que a VC é uma solução, e que o DL evoluiu de CNNs para Transformers... Apesar dos avanços recentes, a literatura ainda apresenta uma lacuna quanto à comparação sistemática e direta entre as arquiteturas de *deep learning* mais modernas, como ResNets, EfficientNets e Transformers, aplicadas especificamente à classificação automatizada do algodão. Em particular, são escassos os estudos que avaliam de forma integrada os *trade-offs* entre acurácia e eficiência computacional, aspectos fundamentais para a viabilidade de implementação em ambientes industriais. Diante disso, este trabalho busca preencher essa lacuna, fornecendo uma análise comparativa que possa subsidiar decisões técnicas mais embasadas no desenvolvimento de sistemas aplicáveis ao setor produtivo.

METODOLOGIA

Nesta seção, são detalhados os procedimentos e as ferramentas desenvolvidas para a aquisição de dados, que constituem a base para o treinamento e validação do sistema de visão computacional proposto. A metodologia foi dividida em duas etapas principais: (1) o desenvolvimento de um sistema de hardware para aquisição padronizada de imagens, doravante denominado “Caixa de Captura”; (2) o estabelecimento de um protocolo rigoroso para a coleta das amostras de algodão em ambiente industrial; o (3) pré-processamento e preparação dos dados; e (4) o ambiente de treinamento e avaliação dos modelos. Cada etapa foi projetada com foco na robustez, padronização e reprodutibilidade dos resultados, pilares fundamentais para a validação científica do estudo.

3.1 Desenvolvimento do Sistema de Aquisição de Dados (Caixa de Captura)

Para assegurar a uniformidade das imagens e minimizar interferências causadas por variações ambientais, desenvolveu-se um sistema de captura dedicado, composto por três elementos principais: uma estrutura física controlada, um sistema de iluminação multiespectral e uma câmera de alta resolução. Essa configuração foi projetada para oferecer condições ideais e reprodutíveis de aquisição de imagens, fundamentais para a qualidade do processo de classificação automatizada.

A estrutura física consiste em uma caixa fechada de MDF, com interior branco e opaco, para bloquear a luz externa e evitar contaminação de cor. A câmera foi montada no topo, em uma posição fixa e vertical, garantindo enquadramento e foco consistentes em todas as capturas. Uma imagem do equipamento é apresentado da Figura 4.

O sistema de iluminação é composto por duas fitas de LED de alta intensidade (2000 lm/m) posicionadas na parte superior para fornecer iluminação difusa e uniforme, evitando

sombras e brilho especular. Foram utilizadas duas temperaturas de cor distintas: 2800K (luz "quente") para realçar o amarelamento da fibra e 6000K (luz "fria") para destacar impurezas. As imagens foram capturadas sob três configurações de iluminação controladas por software: apenas 2800K, apenas 6000K e ambas simultaneamente, criando um dataset robusto para treinar os modelos sob diferentes espectros de luz.

Para a captura de imagem, foi utilizada uma câmera com sensor CMOS, capturando imagens com resolução de 1280x720 pixels. Optou-se por um sensor CMOS devido ao seu menor custo, menor consumo de energia e facilidade de integração, características alinhadas aos requisitos de um sistema de baixo custo para implantação industrial, conforme discutido no Capítulo 2. Utilizou-se uma lente com ângulo de visão de 140° garantiu a captura completa da amostra dentro do sistema, otimizando o design do equipamento.



Figura 4 – Equipamento de coleta de amostras


3.2 Protocolo de Coleta e Amostragem

O processo de coleta de dados foi realizado diretamente no ambiente de uma algodoeira localizada na região de Sapezal, Mato Grosso, um polo produtivo relevante no cerrado brasileiro. Seguiu-se um protocolo padronizado para garantir a rastreabilidade e a integridade de cada amostra. O fluxo de trabalho é descrito a seguir e ilustrado na Figura 5:

1. Identificação da Amostra: O operador utiliza um leitor de código de barras para escanear a etiqueta de identificação da amostra. Diversas informações, como o ID do fardo, data de processamento, lote, origem e outras variáveis relevantes, são automaticamente vinculadas aos arquivos de imagem gerados. Esse processo assegura a rastreabilidade dos dados e a correta associação entre as imagens e suas respectivas amostras.

2. Posicionamento: A amostra de algodão é retirada de sua embalagem e posicionada no centro da base da Caixa de Captura. Em seguida, o operador ajusta manualmente a amostra, buscando garantir que sua superfície esteja o mais plana, uniforme e representativa possível, de modo a assegurar a qualidade e a reprodutibilidade da imagem capturada.
3. Captura Automatizada: Por meio de uma interface em um *laptop* conectado ao sistema, o operador inicia o processo de captura. O *software*, então, executa automaticamente a sequência de iluminação pré-programada, composta por luz quente (AM), luz fria (BR) e ambas simultaneamente (AB), capturando uma imagem de alta resolução para cada condição. As três imagens resultantes são armazenadas e vinculadas ao código de barras previamente escaneado, garantindo a associação correta entre os dados e a respectiva amostra.
4. Manipulação (Opcional): Em determinadas amostras, o operador reposiciona o material, reorientando ou afofando levemente sua superfície, e realiza uma segunda captura com o objetivo de registrar a variabilidade interna do algodão e assegurar uma representação mais fiel de suas características visuais.
5. Finalização: Após a captura, a amostra é removida da caixa e o operador prossegue para a amostra seguinte, repetindo o processo.

Figura 5 – Fluxograma do processo de coleta de amostras e aquisição de imagens.



A execução desse protocolo resultou na criação de um conjunto de dados robusto e de alta qualidade, composto por várias imagens de amostras de algodão, cada uma com identificação única e obtida sob condições de iluminação controladas e variadas. Esse conjunto de dados está devidamente estruturado para ser utilizado nas etapas subsequentes de pré-processamento, treinamento e validação dos modelos de classificação.

3.3 Pré-processamento e preparação dos dados

O conjunto de dados inicial, composto por 3.852 imagens brutas, sendo 1.284 para cada uma das três configurações de iluminação (2800K, 6000K e ambas), passou por um rigoroso fluxo de pré-processamento para otimizar a extração de características e padronizar os dados para o treinamento dos modelos de deep learning.

A primeira etapa consistiu na segmentação do algodão para isolá-lo do fundo da imagem. Para isso, foi aplicado um algoritmo de limiarização adaptativa (adaptive thresholding) em conjunto com operações morfológicas, como abertura e fechamento, para remover ruídos e garantir a extração precisa da área de interesse correspondente à amostra de algodão. A limiarização adaptativa foi preferível a métodos globais, como o de Otsu, por sua maior robustez a pequenas variações de iluminação na superfície da amostra, garantindo uma segmentação mais precisa das bordas da fibra contra o fundo. Essa abordagem assegura que apenas as informações visuais da fibra sejam utilizadas nas etapas subsequentes, eliminando qualquer interferência do ambiente de captura.

Após a segmentação, cada imagem de amostra foi particionada em múltiplos recortes (patches) não sobrepostos de dimensão fixa 224x224 pixels. Esta técnica, conhecida como patching, serve a dois propósitos principais: (1) aumenta significativamente o volume do conjunto de dados de treinamento, permitindo que o modelo seja exposto a uma maior variabilidade de texturas e padrões locais da fibra; e (2) padroniza o tamanho da entrada para os modelos de deep learning, que tipicamente exigem entradas de dimensões uniformes. Este processo resultou em um dataset final robusto e ampliado, pronto para o treinamento e a avaliação das arquiteturas neurais.

3.4 Construção do Conjunto de Dados, Rotulagem e Balanceamento de Classes

O escopo da coleta foi direcionado para as 10 classes de tipo de algodão mais prevalentes na produção local, conforme os padrões estabelecidos pela Instrução Normativa n. 24/2016 do MAPA. A rotulagem de cada amostra foi realizada com base no processo de classificação visual manual adotado pela própria algodoeira, conduzido por classificadores humanos treinados. Esse procedimento assegurou que os rótulos atribuídos ao conjunto de dados correspondessem diretamente aos utilizados nas operações comerciais, tornando o problema de classificação representativo das condições reais da aplicação industrial.

Após a etapa de pré-processamento descrita na Seção 3.3, que incluiu a segmentação da fibra e o particionamento em *patches* de 224x224 pixels, o dataset resultante apresentou um desbalanceamento natural entre as classes. A distribuição original de imagens por classe é detalhada na Tabela 3.

Tabela 3 – Distribuição original de imagens (patches) por classe no dataset.

Classe/Tipo do Algodão	Nº de Imagens	Classe (Tipo)	Nº de Imagens
31.2	1407	32.4	344
31.3	1222	41.4	297
31.4	1396	41.5	292
32.3	1071	42.4	376
33.3	1297	44.4	211

Fonte: Do autor.

O conjunto de dados final foi dividido em dois subconjuntos: 80% destinado ao treinamento e 20% à validação. Essa divisão foi realizada de forma estratificada para manter a proporção das classes em ambos os conjuntos, utilizando um *random seed* fixo (e.g., 42) para garantir a total reprodutibilidade dos experimentos. Para mitigar os efeitos do desbalanceamento entre classes, que podem enviesar o aprendizado do modelo em favor das classes com maior representatividade, aplicou-se uma estratégia de oversampling exclusivamente no conjunto de treinamento. Essa abordagem permitiu manter a distribuição original de classes no conjunto de validação, assegurando uma estimativa mais realista de desempenho. As classes minoritárias foram aumentadas artificialmente até que todas as 10 classes alcançassem o mesmo número de amostras da classe majoritária (1.407 imagens). Esse balanceamento foi obtido por meio de uma composição de técnicas de data augmentation, utilizando a biblioteca Albumentations em Python, com transformações geométricas e fotométricas aplicadas às imagens.

- Transformações Geométricas: Rotações aleatórias (até 20 graus), inversões horizontais e verticais, e transformações afins (translação, escala e cisalhamento).
- Transformações Fotométricas: Ajustes aleatórios de brilho e contraste.

Esta abordagem assegura que o modelo seja treinado com uma representação equitativa de todas as classes, enquanto sua capacidade de generalização é avaliada em um conjunto de dados não visto, que mantém a proporção original do problema.

3.5 Ambiente de treinamento e avaliação dos modelos

Para garantir a reprodutibilidade e a gestão sistemática dos experimentos, foi desenvolvido um ambiente automatizado de treinamento e avaliação. A plataforma foi implementada em Python, utilizando a biblioteca PyTorch como framework principal para a construção e o treinamento dos modelos de deep learning, devido à sua flexibilidade e vasto ecossistema.

A gestão do ciclo de vida dos experimentos foi realizada com a ferramenta MLflow. Esta plataforma permitiu o rastreamento automatizado de todos os artefatos experimentais, incluindo os hiperparâmetros utilizados, as métricas de performance (acurácia, perda), os modelos

treinados e os gráficos de validação. Essa abordagem assegura a comparabilidade rigorosa entre os diferentes modelos e facilita a análise dos resultados, granatindo a transparência do processo.

Para mitigar o overfitting e aumentar a capacidade de generalização dos modelos, foram empregadas as técnicas de regularização CutMix e MixUp em tempo real durante o treinamento, que combinam pares de imagens e seus rótulos para criar amostras sintéticas, incentivando o modelo a aprender representações mais robustas e a fazer previsões menos confiantes em regiões ambíguas.

A otimização de hiperparâmetros foi conduzida de forma sistemática utilizando a biblioteca Optuna, que implementa algoritmos de busca avançados. Especificamente, foi empregada a Otimização Bayesiana com o algoritmo TPE (Tree-structured Parzen Estimator), pois é computacionalmente mais eficiente do que métodos como *grid search* ou *random search* para explorar eficientemente o espaço de hiperparâmetros (como taxa de aprendizado, intensidade do dropout e parâmetros do otimizador) e convergir rapidamente para as configurações que maximizam a acurácia de validação, garantindo assim que cada modelo fosse avaliado em sua performance ótima.

3.6 Desenho Experimental

HIPÓTESES, VARIÁVEIS, MÉTRICAS DE AVALIAÇÃO E TESTES ESTATÍSTICOS

3.7 Modelos Avaliados

3.7.1 ResNet: Aprendizado Residual Profundo

A ResNet (HE *et al.*, 2016) foi selecionada como representante das arquiteturas baseadas em conexões residuais devido ao seu desempenho balanceado entre precisão e eficiência computacional. Com 50 camadas profundas organizadas em blocos *bottleneck* [3, 4, 6, 3], o modelo demonstra 23,85% de erro *top-1* no ImageNet com aproximadamente 25,6 milhões de parâmetros.

A arquitetura resolve fundamentalmente o problema do *vanishing gradient* através de *skip connections* que implementam a função matemática:

$$y = F(x, \{W_i\}) + x \quad (3.1)$$

onde $F(x, \{W_i\})$ representa a função residual aprendida e x a entrada original.

Esta inovação permite treinamento efetivo de redes extremamente profundas, estabelecendo novo paradigma para arquiteturas modernas.

3.7.2 EfficientNet: Compound Scaling Otimizado

A EfficientNet-B4 (TAN; LE, 2019) representa o paradigma de *scaling* sistemático através da metodologia *compound scaling* que balanceia profundidade ($\phi = 1.8$), largura e resolução simultaneamente segundo a fórmula:

$$\text{profundidade: } d = \alpha^\phi, \quad \text{largura: } w = \beta^\phi, \quad \text{resolução: } r = \gamma^\phi \quad (3.2)$$

com restrição $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$.

Com 19,3 milhões de parâmetros processando imagens 380×380, alcança 17,4% de erro *top-1* no ImageNet através de *Mobile Inverted Bottleneck blocks* (MBConv) e módulos *Squeeze-and-Excitation*. A seleção desta variante específica justifica-se pelo equilíbrio otimizado entre precisão e recursos computacionais para aplicações práticas.

3.7.3 VGGNet: Profundidade através da Simplicidade Arquitetural

A VGGNet, proposta por (SIMONYAN; ZISSERMAN, 2014b), representa uma abordagem fundamental no deep learning: alcançar um desempenho superior por meio do aumento significativo da profundidade da rede, mantendo uma arquitetura notavelmente simples e homogênea. Sua presença neste trabalho funciona como um ponto de referência relevante para a avaliação dos ganhos de eficiência proporcionados por arquiteturas mais modernas.

A principal contribuição da VGGNet foi demonstrar que uma pilha de camadas convolucionais com filtros muito pequenos, de dimensão **3x3**, pode superar arquiteturas com filtros maiores. O uso exclusivo de filtros 3x3, que é o menor tamanho capaz de capturar a noção de esquerda/direita, cima/baixo e centro, apresenta duas vantagens cruciais:

1. Aumento da não-linearidade: Uma pilha de três camadas de convolução 3x3 possui o mesmo campo receptivo efetivo de uma única camada 7x7. No entanto, a pilha de três camadas introduz três funções de ativação (ReLU) em vez de uma, tornando a função de decisão mais discriminativa.
2. Redução de parâmetros: A mesma pilha de três camadas 3x3 é parametricamente mais eficiente que uma única camada 7x7. Conforme demonstrado pelos autores, essa decomposição atua como uma forma de regularização, forçando um aprendizado de filtros mais simples.

A arquitetura geral consiste em blocos de 2 a 3 camadas de convolução 3x3, seguidos por uma camada de *max-pooling* 2x2 que reduz a resolução espacial pela metade. O número de canais dobra após cada camada de *pooling* (de 64 para 128, 256 e, finalmente, 512). O modelo utilizado neste trabalho, uma variante da VGG16, é composto por 13 camadas convolucionais e 3 camadas

totalmente conectadas, totalizando um número de parâmetros superior a 120 milhões. Essa alta complexidade a posiciona como o modelo mais "pesado" e computacionalmente intensivo na presente análise comparativa.

3.7.4 Inception: Fatorização de Convoluções e Processamento Multi-escala

A Inception-V3 ([SZEGEDY et al., 2016](#)) representa inovações em fatorização de convoluções e processamento multi-escala através de módulos Inception otimizados para diferentes resoluções espaciais. Com 42 camadas e 23,8 milhões de parâmetros processando imagens 299x299, alcança 21,2% de erro *top-1* no ImageNet.

A arquitetura introduziu factorização sistemática substituindo convoluções 5x5 por duas convoluções 3x3 empilhadas (28% de redução de parâmetros) e implementando factorização assimétrica decompondo convoluções 3x3 em sequências 1x3 seguidas por 3x1 (33% de economia computacional). A inclusão desta arquitetura permite avaliação de técnicas de factorização matemática e regularização por *label smoothing* em classificação de algodão.

3.7.5 ViT

ADICIONAR

3.7.6 Swin-T

ADICIONAR

3.7.7 ConvNeXt

ADICIONAR

RESULTADOS

4.1 Análise Comparativa Global

Os resultados consolidados dos melhores trials de cada modelo, otimizados para acurácia de validação, estão apresentados na Tabela 4. Observa-se que o modelo EfficientNet obteve o melhor desempenho geral, com acurácia de validação de 85,64%, mesmo sendo a arquitetura mais leve entre as avaliadas, com apenas 9,2 milhões de parâmetros. O modelo Inception alcançou a segunda melhor performance, com 81,17% de acurácia, seguido por ResNet (76,65%) e VGGNet (74,84%), que apresentaram desempenhos inferiores.

Além da acurácia, é importante considerar os valores da função de perda, que quantifica o erro entre as previsões do modelo e os valores reais durante o treinamento e a validação. A função de perda permite avaliar a qualidade do ajuste do modelo, mesmo quando a acurácia é alta. Nesse aspecto, observa-se que o modelo EfficientNet apresentou uma perda de validação de 0,8791, o que, em conjunto com sua alta acurácia, reforça sua capacidade de generalização. Já a VGGNet, embora tenha obtido uma perda de validação semelhante (1,0214), apresentou a menor acurácia entre os modelos, indicando uma possível limitação na forma como sua complexidade impacta o aprendizado efetivo.

Destaca-se, portanto, o contraste entre complexidade arquitetônica e desempenho prático: embora a VGGNet possua cerca de 73,5 milhões de parâmetros, aproximadamente oito vezes mais que a EfficientNet, essa maior complexidade não se refletiu em melhor desempenho preditivo, resultando na segunda menor acurácia entre os modelos analisados. Esse cenário evidencia que um maior número de parâmetros não garante, por si só, maior capacidade de generalização, especialmente em contextos com limitações de dados ou risco de sobreajuste ao conjunto de treinamento.

Tabela 4 – Resultados comparativos dos melhores execuções por modelo, otimizados para acurácia de validação.

Modelo	Duração do treinamento	Número de parâmetros	Validação		Treinamento	
			Acurácia	Função de Perda	Acurácia	Função de Perda
EfficientNet	53:24:58	9.2M	85.6432	0.8791	93.7278	0.5509
Inception	46:28:43	31.2M	81.1656	0.8425	96.7217	0.6772
ResNet	34:30:59	24.4M	76.6525	1.0710	96.0821	0.4351
VGGNet	76:18:38	73.5M	74.8401	1.0214	92.6173	0.3333

Fonte: Do autor.

4.2 Análise de desempenho por classe

Embora a acurácia global aponte a superioridade da EfficientNet, uma análise detalhada por classe revela um cenário mais heterogêneo. A Tabela 5 apresenta as métricas de Precisão, Recall e F1-Score para cada uma das 10 classes de algodão, comparando os quatro modelos.

Observa-se que a EfficientNet demonstra um desempenho excepcional em classes como 44.4 (F1-Score de 0.984), 32.4 (0.946) e 42.4 (0.940), indicando uma alta capacidade de aprender características distintivas para esses tipos. Contudo, seu desempenho é visivelmente mais baixo na classe 31.3, com um F1-Score de apenas 0.570. Curiosamente, para esta classe específica, o modelo Inception obteve um desempenho superior (F1-Score de 0.684). Esta análise detalhada evidencia que, embora um modelo seja globalmente superior, sua eficácia pode variar significativamente dependendo da classe em questão.

Tabela 5 – Análise de desempenho por classe do modelo EfficientNet

Classe	Precisão	Revocação	Escore F1
31.2	0.562	0.864	0.681
31.3	0.900	0.417	0.570
31.4	0.696	0.597	0.643
32.3	0.800	0.769	0.784
32.4	0.906	0.989	0.946
33.3	0.693	0.867	0.770
41.4	0.913	0.951	0.932
41.5	0.996	0.840	0.912
42.4	0.925	0.956	0.940
44.4	0.975	0.993	0.984

Fonte: Do autor.

4.3 Análise qualitativa dos erros de classificação

A Figura 6 apresenta a matriz de confusão normalizada do modelo EfficientNet, com o objetivo de oferecer uma análise mais detalhada dos erros de classificação das amostras

de algodão. Nessa matriz, os valores localizados na diagonal principal representam a taxa de revocação de cada classe, ou seja, a proporção de amostras corretamente classificadas em relação ao total de amostras reais daquela classe. Os valores fora da diagonal indicam as proporções de classificações incorretas, revelando os padrões e direções mais frequentes dos erros cometidos pelo modelo.

A matriz corrobora os resultados apresentados na Tabela 3, indicando o bom desempenho geral da EfficientNet. Observa-se revocação superior a 0,95 nas classes 32.4, 41.4, 42.4 e 44.4, o que sugere que essas categorias apresentam características visuais mais consistentes e discriminativas, facilitando o reconhecimento automático por parte do modelo.

Em contraste, a classe 31.3 se destaca como a mais desafiadora, com apenas 45% das amostras corretamente classificadas. A análise das classificações incorretas revela uma dispersão significativa dos erros, com amostras dessa classe sendo atribuídas, de forma equivocada, às classes 31.2 (10%), 41.5 (10%), 33.3 (7%) e 31.4 (6%). Esse padrão de confusão sugere que a classe 31.3 possui alta variabilidade intraclasse ou características visuais sobrepostas com múltiplas outras classes, dificultando sua distinção precisa.

Adicionalmente, verifica-se que os erros das demais classes tendem a ocorrer entre categorias visualmente similares ou adjacentes no espaço amostral, como entre as classes 31.4 e 31.3, ou entre 41.5 e 41.4. Tal comportamento é coerente com a lógica morfológica do algodão, em que atributos como cor, forma, tamanho e textura podem se sobrepor entre diferentes tipos de fibra. Esse tipo de erro estruturado evidencia que, embora existam limitações pontuais, o modelo demonstra coerência semântica nas confusões, o que pode ser vantajoso em estratégias futuras de reclassificação hierárquica ou na aplicação de modelos especializados por subgrupo varietal.




Figura 6 – Matriz de confusão

DISCUSSÃO

CONCLUSÃO

REFERÊNCIAS

ABBADE, E. B. O papel do agronegócio brasileiro no seu desenvolvimento econômico. **Revista Gestão da Produção Operações e Sistemas**, v. 9, n. 3, p. 149, ago. 2014. Disponível em: <https://revista.feb.unesp.br/gepros/article/view/1053>. Citado nas páginas 33 e 37.

AHAD, M. T.; LI, Y.; SONG, B.; BHUIYAN, T. Comparison of CNN-based deep learning architectures for rice diseases classification. **Artificial Intelligence in Agriculture**, Elsevier, v. 9, p. 22–35, 2023. Citado na página 47.

BALLARD, D. H.; BROWN, C. M. **Computer Vision**. Englewood Cliffs, NJ, USA: Prentice Hall, 1982. ISBN 9780131653160. Citado nas páginas 30 e 43.

BASSO, M. F.; NEVES, M. F.; SA, M. F. Grossi-de. Agriculture evolution, sustainability and trends, focusing on brazilian agribusiness: A review. **Frontiers in Sustainable Food Systems**, Frontiers, v. 7, p. 1–18, 2024. Disponível em: <https://www.frontiersin.org/articles/10.3389/fsufs.2023.1296337/full>. Citado nas páginas 33 e 34.

BIGAS, M.; CABRUJA, E.; FOREST, J.; SALVI, J. Review of cmos image sensors. **Microelectronics Journal**, Elsevier, v. 37, n. 5, p. 433–451, 2006. Citado na página 44.

BRAZIL, C. **Central laboratory ensures credibility to Brazilian cotton quality testing**. 2021. Accessed December 2024. Disponível em: <https://cottonbrazil.com/central-laboratory-ensures-credibility-to-brazilian-cotton-quality-testing/>. Citado na página 41.

BROSNAN, T.; SUN, D.-W. Inspection and grading of agricultural and food products by computer vision systems - a review. **Computers and Electronics in Agriculture**, v. 61, p. 193–213, 11 2002. Citado nas páginas 31 e 45.

_____. Improving quality inspection of food products by computer vision—a review. **Journal of Food Engineering**, Elsevier, v. 61, n. 1, p. 3–16, 2004. Citado na página 43.

CARDOSO, V. M.; COSTA, C. C. d.; UEDA, B. E.; GILIO, L. Perspectivas para as exportações do agronegócio brasileiro em 2024. **Comércio Internacional | Insper Agro Global**, Insper Agro Global, Setembro 2024. Working paper n.5/2024. Disponível em: <https://agro.insper.edu.br/>. Citado na página 34.

CHEN, Y.-R.; CHAO, K.; KIM, M. S. Machine vision technology for agricultural applications. **Computers and Electronics in Agriculture**, Elsevier, v. 36, n. 2-3, p. 173–191, 2002. Citado na página 44.

CHENG, L.; GHORASHI, H.; DUCKETT, K.; ZAPLETALOVA, T.; WATSON, M. Color grading of cotton part II: Color grading with an expert system and neural networks. **Textile Research Journal**, Sage Publications, v. 69, n. 12, p. 893–903, 1999. Citado na página 47.

- CHUQUIMARCA, L. E.; VINTIMILLA, B. X.; VELASTIN, S. A. A review of external quality inspection for fruit grading using cnn models. **Artificial Intelligence in Agriculture**, Elsevier B.V. on behalf of KeAi Communications Co., Ltd., v. 14, p. 1–20, 2024. ISSN 2589-7217. Open access under CC BY 4.0. Citado na página 49.
- CONAB, C. N. d. A. **Série Histórica das Safras**. 2024. Disponível em: <<https://www.conab.gov.br/info-agro/safras/serie-historica-das-safras>>. Acesso em: 26 out. 2024. Citado na página 29.
- CONANT, L. J. The united states cotton futures act. **The American Economic Review**, American Economic Association, v. 5, n. 1, p. 1–11, 1915. Disponível em: <<https://www.jstor.org/stable/71>>. Citado na página 35.
- Cotton Incorporated. **Classification of Cotton**. 2017. Acessado em: 27 out. 2024. Disponível em: <<https://www.cottoninc.com/wp-content/uploads/2017/02/Classification-of-Cotton.pdf>>. Citado na página 29.
- _____. **HVI Color Chart - U.S. Cotton Fiber Chart**. 2024. Acesso em: 9 nov. 2024. Disponível em: <<https://www.cottoninc.com/cotton-production/quality/us-cotton-fiber-chart/hvi-color-chart/>>. Citado na página 42.
- CUBERO, S.; ALEIXOS, N.; MOLTÓ, E.; GÓMEZ-SANCHIS, J.; BLASCO, J. Advances in machine vision applications for automatic inspection and quality evaluation of fruits and vegetables. **Food and Bioprocess Technology**, Springer, v. 4, n. 4, p. 487–504, 2010. Citado na página 45.
- DAS, S.; RAY, M. K.; PANDAY, D.; MISHRA, P. K. Role of biotechnology in creating sustainable agriculture. **PLOS Sustainability and Transformation**, Public Library of Science, v. 2, n. 7, p. 1–13, 07 2023. Disponível em: <<https://doi.org/10.1371/journal.pstr.0000069>>. Citado na página 34.
- DING, W.; ABDEL-BASSET, M.; ALRASHDI, I.; HAWASH, H. Next generation of computer vision for plant disease monitoring in precision agriculture: A contemporary survey, taxonomy, experiments, and future direction. **Information Sciences**, Elsevier, v. 665, p. 120338, 2024. Citado na página 47.
- EARLE, D. E.; DEAN, W. S. **The Classification and Grading of Cotton**. Washington, DC: US Department of Agriculture, Farmers' Bulletin No. 591, 1914. Contribuição do Bureau de Tecnologia Agrícola e Padronização do Algodão. Citado na página 35.
- FILHO, U. A. S.; LOPES, R. L.; JUNIOR, C. A. G.; ESTEVES, E. G. Z.; SESSO, P. P. Produto interno bruto e pegada hídrica do agronegócio: comparativo entre países. **Revista de Economia e Sociologia Rural**, Sociedade Brasileira de Economia e Sociologia Rural, v. 62, n. 4, p. e274229, 2024. ISSN 0103-2003. Disponível em: <<https://doi.org/10.1590/1806-9479.2023.274229pt>>. Citado na página 33.
- FISHER, O. J.; RADY, A.; EL-BANNA, A. A.; WATSON, N. J.; EMAISH, H. H. An image processing and machine learning solution to automate Egyptian cotton lint grading. **Textile Research Journal**, Sage Publications, v. 93, n. 11-12, p. 2558–2575, 2023. Citado na página 50.
- GHAZAL, S.; MUNIR, A.; QURESHI, W. S. Computer vision in smart agriculture and precision farming: Techniques and applications. **Artificial Intelligence in Agriculture**, Elsevier B.V. on

behalf of KeAi Communications Co., Ltd., v. 13, p. 64–83, 2024. ISSN 2589-7217. Open access under CC BY-NC-ND 4.0. Citado na página 49.

GONÇALVES, E. M. d. O.; TIBOLA, G.; VARGAS, G. M.; MACHADO, A. S.; NECKEL, A.; MORO, L. D.; MORES, G. Os principais desafios da logística de transporte do agronegócio brasileiro: uma revisão sistemática da literatura. v. 15, p. e4073, ago. 2024. Disponível em: <<https://ojs.revistagesec.org.br/secretariado/article/view/4073>>. Citado na página 33.

GUNASEKARAN, S. Computer vision technology for food quality assurance. **Trends in Food Science & Technology**, Elsevier, v. 7, p. 245–256, 1996. Citado na página 45.

GUO, Z.; GENG, Y.; WANG, C.; XUE, Y.; SUN, D.; LOU, Z.; CHEN, T.; GENG, T.; QUAN, L. Instacropnet: An efficient unet-based architecture for precise crop row detection in agricultural applications. **Artificial Intelligence in Agriculture**, KeAi Communications Co., Ltd. Elsevier B.V., v. 12, p. 85–96, 2024. Open access under CC BY-NC-ND 4.0. Citado na página 48.

HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep residual learning for image recognition. **Proceedings of the IEEE conference on computer vision and pattern recognition**, p. 770–778, 2016. Citado nas páginas 50 e 58.

HENG, C.; CHEN, L.; SHEN, H.; WANG, F. Study on the measurement and evaluation of cotton color using image analysis. **Materials Research Express**, IOP Publishing, v. 7, n. 7, p. 075101, 2020. Citado na página 49.

INCORPORATED, C. **The Classification of Cotton**. Cary, NC: Cotton Incorporated, 2020. Produzido com o suporte do Cotton Council International e o USDA Agricultural Marketing Service. Citado na página 35.

JIANG, L.; JIANG, H.; JING, X.; DANG, H.; LI, R.; CHEN, J.; MAJEED, Y.; SAHNI, R.; FU, L. Uav-based field watermelon detection and counting using yolov8s with image panorama stitching and overlap partitioning. **Artificial Intelligence in Agriculture**, KeAi Communications/Elsevier, v. 13, p. 117–127, 2024. Open access under CC BY-NC-ND 4.0. Citado na página 47.

JUWONO, F. H.; WONG, W.; VERMA, S.; SHEKHAWAT, N.; LEASE, B. A.; APRIONO, C. Machine learning for weed-plant discrimination in agriculture 5.0: An in-depth review. **Artificial Intelligence in Agriculture**, Elsevier, v. 10, p. 13–25, 2023. Citado nas páginas 47 e 48.

KHAN, M. A.; WAHID, A.; AHMAD, M.; TAHIR, M. T.; AHMED, M.; AHMAD, S.; HASANUZZAMAN, M. World cotton production and consumption: An overview. In: _____. **Cotton Production and Uses: Agronomy, Crop Protection, and Postharvest Technologies**. Singapore: Springer Singapore, 2020. p. 1–7. ISBN 978-981-15-1472-2. Disponível em: <https://doi.org/10.1007/978-981-15-1472-2_1>. Citado na página 29.

KLANCAR, G.; KRISTAN, M.; KOVACIC, S.; ORQUEDA, O. Robust and efficient vision system for group of cooperating mobile robots with application to soccer robots. **ISA Transactions**, ISA—The Instrumentation, Systems, and Automation Society, v. 43, n. 3, p. 329–342, 2004. ISSN 0019-0578. Received 9 Dec 2002; accepted 28 Sep 2003. Citado na página 48.

KNOWLTON, J. L. Usda cotton classing and the need for a universal cotton quality evaluation system. In: **EFS@ Systems Conference, Turkey**, <http://www.cottoninc.com/EFSSConference>. [S.l.: s.n.], 2005. Citado na página 35.

- KRUTZ, G. W.; GIBSON, H. G.; CASSENS, D. L.; MIN, Z. M. Z. Colour vision in forest and wood engineering. 2000. Citado na página 45.
- LIN, J.; QIAN, T. Switch between el nino and la nina is caused by subsurface ocean waves likely driven by lunar tidal forcing. **Scientific Reports**, v. 9, n. 1, 2019. Disponível em: <<https://doi.org/10.1038/s41598-019-49678-w>>. Citado na página 33.
- LITTWILLER, D. M. **CCD vs CMOS: Facts and Fiction**. 2001. Disponível em: <<https://courses.cs.duke.edu/fall11/cps274/papers/Littwiller01.pdf>>. Acesso em: 17 nov. 2024. Citado na página 43.
- LU, H.; CAO, Z.; XIAO, Y.; FANG, Z.; ZHU, Y.; XIAN, K. Fine-grained maize tassel trait characterization with multi-view representations. **Computers and Electronics in Agriculture**, Elsevier, v. 118, p. 143–158, 2015. Citado na página 47.
- LV, Y.; GAO, Y.; RIGALL, E.; QI, L.; GAO, F.; DONG, J. Cotton appearance grade classification based on machine learning. **Procedia Computer Science**, Elsevier, v. 174, p. 729–734, 2020. Citado na página 50.
- MAJUMDAR, S.; JAYAS, D. S. Classification of bulk samples of cereal grains using machine vision. **J. Agric. Engng Res.**, Elsevier, v. 73, n. 1, p. 35–47, 1999. Citado na página 48.
- MAPA, M. d. A. P. e. A. **Instrução Normativa Nº 24, de 14 de Julho de 2016**. 2016. Disponível em: <https://www.in.gov.br/materia/-/asset_publisher/Kujrw0TZC2Mb/content/id/21289371/do1-2016-07-15-instrucao-normativa-n-24-de-14-de-julho-de-2016-21289194>. Acesso em: 26 out. 2024. Citado nas páginas 29, 30 e 36.
- MARR, D. From computational theory to psychology and neurophysiology: A case study from vision. **MIT Artificial Intelligence Laboratory Working Paper**, Cambridge, MA, n. 131, 1976. Discussão sobre níveis de descrição em processamento de informação visual e exemplos práticos. Citado na página 43.
- MATUSIAK, M.; WALAWSKA, A. Important aspects of cotton colour measurement. **Fibres e Textiles in Eastern Europe**, v. 18, p. 17–23, 2010. Citado na página 38.
- MORAIS, J. P. S.; FARIAS, F. J. C.; BELOT, J.-L.; MARTINS, R. S. A.; MIZOGUCHI, E. T. **Interpretação das características avaliadas no SITC para qualidade de fibra de algodão - Uma abordagem prática**. Campina Grande, PB: Embrapa Algodão, 2021. (Documentos / Embrapa Algodão, 285). ISSN 0103-0205. Citado na página 35.
- NICKERSON, D.; NEWTON, F. E. **Grade and Color Indexes Developed for Evaluating Results of USDA Cotton Finishing Tests**. Washington, D.C.: United States Department of Agriculture, Agricultural Marketing Service, Cotton Division, 1958. Documento histórico arquivado. Citado na página 41.
- OLIVEIRA, D. d. M.; HONORATO, L. B. Visão computacional. **Universidade Estadual de Campinas, Faculdade de Tecnologia**, Limeira, SP, Brasil, 2024. Artigo introdutório sobre visão computacional com foco em rastreamento de olhar. Citado nas páginas 30, 42 e 43.
- OLIVEIRA, D. G. D. B. **Classificação e Determinação dos Atributos de Qualidade das Fibras de Algodão Utilizando um Espectrômetro Raman Portátil e Quimiometria**. 104 f. Dissertação (Mestrado em Química) — Universidade Estadual da Paraíba, Campina Grande, PB, Brasil, 2022. Citado na página 30.

PATRÍCIO, D. I.; RIEDER, R. Computer vision and artificial intelligence in precision agriculture for grain crops: A systematic review. **Computers and Electronics in Agriculture**, Elsevier, v. 153, p. 69–81, 2018. Citado nas páginas 46 e 49.

PAYMODE, A. S.; MALODE, V. B. Transfer Learning for Multi-Crop Leaf Disease Image Classification using Convolutional Neural Network VGG. **Artificial Intelligence in Agriculture**, Elsevier, v. 6, p. 23–33, 2022. Citado na página 47.

RAMOS, L.; CASAS, E.; BENDEK, E.; ROMERO, C.; RIVAS-ECHEVERRIA, F. Hyperparameter optimization of YOLOv8 for smoke and wildfire detection: Implications for agricultural and environmental safety. **Artificial Intelligence in Agriculture**, Elsevier, v. 12, p. 109–126, 2024. Citado nas páginas 47 e 48.

RIBEIRO, T. P.; ARRAES, F. B. M.; LOURENÇO-TESSUTTI, I. T.; SILVA, M. S.; Sá, M. E. Lisei-de; LUCENA, W. A.; MACEDO, L. L. P.; LIMA, J. N.; AMORIM, R. M. S.; ARTICO, S.; ALVES-FERREIRA, M.; SILVA, M. C. M.; SA, M. F. Grossi-de. Transgenic cotton expressing cry10aa toxin confers high resistance to the cotton boll weevil. **Plant Biotechnology Journal**, v. 15, n. 8, p. 997–1009, 2017. Disponível em: <<https://onlinelibrary.wiley.com/doi/abs/10.1111/pbi.12694>>. Citado na página 34.

RIBEIRO, T. P.; BASSO, M. F.; CARVALHO, M. H. de; MACEDO, L. L. P. de; SILVA, D. M. L. da; LOURENÇO-TESSUTTI, I. T.; OLIVEIRA-NETO, O. B. de; CAMPOS-PINTO, E. R. de; LUCENA, W. A.; SILVA, M. C. M. da; TRIPODE, B. M. D.; ABREU-JARDIM, T. P. F.; MIRANDA, J. E.; ALVES-FERREIRA, M.; MORGANTE, C. V.; SA, M. F. G. de. Stability and tissue-specific cry10aa overexpression improves cotton resistance to the cotton boll weevil. **Biotechnology Research and Innovation**, v. 3, p. 27–41, 2019. ISSN 2452-0721. Strategies for crop improvement under biotic and abiotic stresses. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2452072119301352>>. Citado na página 34.

RIBEIRO, T. P.; VASQUEZ, D. D. N.; MACEDO, L. L. P.; LOURENÇO-TESSUTTI, I. T.; VALENÇA, D. C.; OLIVEIRA-NETO, O. B.; MELO, B. Paes-de; RODRIGUES-SILVA, P. L.; FIRMINO, A. A. P.; BASSO, M. F.; LINS, C. B. J.; NEVES, M. R.; MOURA, S. M.; TRIPODE, B. M. D.; MIRANDA, J. E.; SILVA, M. C. M.; SA, M. F. Grossi-de. Stabilized double-stranded rna strategy improves cotton resistance to cbw (*anthonomus grandis*). **International Journal of Molecular Sciences**, v. 23, n. 22, 2022. ISSN 1422-0067. Disponível em: <<https://www.mdpi.com/1422-0067/23/22/13713>>. Citado na página 34.

RITHARSON, P. I.; RAIMOND, K.; MARY, X. A.; ROBERT, J. E.; ANDREW, J. DeepRice: A deep learning and deep feature based classification of Rice leaf disease subtypes. **Artificial Intelligence in Agriculture**, Elsevier, v. 11, p. 34–49, 2023. Citado na página 47.

SALDAÑA, E.; SICHE, R.; HUAMÁN, R.; LUJÁN, M.; CASTRO, W.; QUEVEDO, R. Review: Computer vision applied to the inspection and quality control of fruits and vegetables. **Brazilian Journal of Food Technology**, Instituto de Tecnologia de Alimentos, v. 16, n. 4, p. 254–272, 2013. Citado na página 43.

SHIRAI, Y. **Three-Dimensional Computer Vision**. Berlin, Heidelberg: Springer-Verlag, 1987. 28–30 p. ISBN 978-3-642-82431-9. Citado na página 46.

SHWETHA, V.; BHAGWAT, A.; LAXMI, V. LeafSpotNet: A deep learning framework for detecting leaf spot disease in jasmine plants. **Artificial Intelligence in Agriculture**, Elsevier, v. 12, p. 1–18, 2024. Citado na página 47.

SIMONYAN, K.; ZISSERMAN, A. Very deep convolutional networks for large-scale image recognition. **CoRR**, abs/1409.1556, 2014. Disponível em: <<http://arxiv.org/abs/1409.1556>>. Citado na página 50.

_____. Very deep convolutional networks for large-scale image recognition. **arXiv preprint arXiv:1409.1556**, 2014. Citado na página 59.

SINGH, N.; TEWARI, V.; BISWAS, P.; DHURUW, L. Lightweight convolutional neural network models for semantic segmentation of in-field cotton bolls. **Artificial Intelligence in Agriculture**, Elsevier, v. 8, p. 1–19, 2023. Citado na página 48.

SONKA, M.; HLAVAC, V.; BOYLE, R. **Image Processing, Analysis, and Machine Vision**. London, UK: Chapman & Hall, 1993. 112–191 p. ISBN 978-0-412-45570-4. Citado na página 46.

SUBEESH, A.; BHOLE, S.; SINGH, K.; CHANDEL, N. S.; RAJWADE, Y. A.; RAO, K. V. R.; KUMAR, S. P.; JAT, D. Deep convolutional neural network models for weed detection in polyhouse grown bell peppers. **Artificial Intelligence in Agriculture**, Elsevier B.V. on behalf of KeAi Communications Co., Ltd., v. 6, p. 47–54, 2022. ISSN 2589-7217. Open access under CC BY-NC-ND 4.0. Disponível em: <<https://doi.org/10.1016/j.aia.2022.01.002>>. Citado na página 48.

SUN, D.-W. Inspecting pizza topping percentage and distribution by a computer vision method. **Journal of Food Engineering**, Elsevier, v. 44, n. 4, p. 245–249, 2000. Citado na página 45.

SZEGEDY, C.; VANHOUCKE, V.; IOFFE, S.; SHLENS, J.; WOJNA, Z. Rethinking the inception architecture for computer vision. **Proceedings of the IEEE conference on computer vision and pattern recognition**, p. 2818–2826, 2016. Citado nas páginas 50 e 60.

TAN, M.; LE, Q. V. Efficientnet: Rethinking model scaling for convolutional neural networks. **Proceedings of the 36th International Conference on Machine Learning**, p. 6105–6114, 2019. Citado nas páginas 50 e 59.

THOMASSON, J.; SHEARER, S.; BYLER, R. Image-processing solution to cotton color measurement problems: Part i. instrument design and construction. **Transactions of the American Society of Agricultural Engineers**, v. 48, 03 2005. Citado na página 31.

THOMASSON, J. A.; SHEARER, S. A.; BYLER, R. K. Image-processing solution to cotton color measurement problems: Part i. instrument design and construction. **Transactions of the ASAE**, American Society of Agricultural Engineers, v. 48, n. 2, p. 421–438, 2005. Citado na página 49.

TIAN, H.; WANG, T.; LIU, Y.; QIAO, X.; LI, Y. Computer vision technology in agricultural automation—a review. **Information Processing in Agriculture**, Elsevier, v. 7, n. 1, p. 1–19, 2020. Citado na página 46.

Uster Technologies. **Uster HVI - Cotton Classing**. 2024. Acesso em: 9 nov. 2024. Disponível em: <<https://www.uster.com/products/cotton-classing/uster-hvi/>>. Citado na página 40.

UTKU, H. Application of the feature selection method to discriminate digitized wheat varieties. **Journal of Food Engineering**, Elsevier, v. 46, n. 3, p. 211–216, 2000. Citado nas páginas 47 e 48.

VAINA, L. M. Contributions of david marr to vision and neuroscience. **Encyclopedia of Cognitive Science**, Wiley, 2004. Explora as contribuições de Marr para a visão computacional e a neurociência teórica. Citado na página 43.

WANG, R.; ZHANG, Z.-F.; YANG, B.; XI, H.-Q.; ZHAI, Y.-S.; ZHANG, R.-L.; GENG, L.-J.; CHEN, Z.-Y.; YANG, K. Detection and classification of cotton foreign fibers based on polarization imaging and improved YOLOv5. **Sensors**, MDPI, v. 23, n. 9, p. 4415, 2023. Citado nas páginas 46 e 48.

XIE, C.; CANG, Y.; LOU, X.; XIAO, H.; XU, X.; LI, X.; ZHOU, W. A novel approach based on a modified mask r-cnn for the weight prediction of live pigs. **Artificial Intelligence in Agriculture**, Elsevier B.V. on behalf of KeAi Communications Co., Ltd., v. 12, p. 19–28, 2024. ISSN 2589-7217. Open access under CC BY 4.0. Citado na página 48.

XU, B.; DALE, D.; HUANG, Y. Cotton color classification by fuzzy logic. **2002 Beltwide Cotton Conferences, Atlanta, GA–January 8-12**, National Cotton Council, 2002. Citado na página 49.

YANG, W.; LU, S.; WANG, S.; LI, D. Fast recognition of foreign fibers in cotton lint using machine vision. **Mathematical and Computer Modelling**, Elsevier, v. 54, n. 3-4, p. 877–882, 2011. Citado na página 50.

YAŞAR, S. Quality parameters of cotton fibre. In: _____. **Cotton Production Under Abiotic Stress**. Diyarbakir, Turkey: Springer, 2021. cap. 8, p. 215–234. Disponível em: <<https://doi.org/10.1007/978-3-030-77278-1>>. Citado na página 29.

ZAYAS, I.; MARTIN, C.; STEELE, J.; KATSEVICH, A. Wheat classification using image analysis and crush-force parameters. **Transactions of the ASAE**, American Society of Agricultural Engineers, v. 39, n. 6, p. 2199–2204, 1996. Citado na página 46.

ZHANG, C.; LI, T.; LI, J. Detection of impurity rate of machine-picked cotton based on improved canny operator. **Electronics**, MDPI, v. 11, n. 7, p. 974, 2022. Citado na página 49.

ZHANG, H.; LI, D. Applications of computer vision techniques to cotton foreign matter inspection: A review. **Computers and Electronics in Agriculture**, Elsevier, v. 109, p. 59–70, 2014. Citado nas páginas 31 e 44.

_____. Applications of computer vision techniques to cotton foreign matter inspection: A review. **Computers and Electronics in Agriculture**, Elsevier, v. 109, p. 59–70, 2014. Citado na página 48.

ZHU, H.; YANG, L.; WANG, Y.; WANG, Y.; HOU, W.; RAO, Y.; LIU, L. Enhanced detection algorithm for apple bruises using structured light imaging. **Artificial Intelligence in Agriculture**, Elsevier, v. 11, p. 50–60, 2024. Citado nas páginas 46, 47 e 48.

APÊNDICE

A

APÊNDICE 1

ESTE É UM APENDICE

REPOSITÓRIO GIT

[<https://github.com/rodrigoqaz/mecai.dissertacao>](https://github.com/rodrigoqaz/mecai.dissertacao) Repositório com todos os códigos produzidos nesta dissertação;

